Pred Propensity

Bộ số liệu MBD-mini được lấy trên huggingface

Kích thước bằng 10% bộ số liệu gốc (MultimodalBankingDataset)

100.224 khách hàng

12 tháng nhãn

3 nguồn hành vi



Giá trị thiếu theo từng bảng

Phạm vi: toàn dữ liệu gốc · dòng có ít nhất một thuộc tính null

Bảng	Tổng dòng	Tổng cột	Dòng có null	Cột có null	Tỷ lệ dòng
Khách hàng	100.224	2	0	0	**0,000%**
Nhãn (target)	1.202.688	9	120.786	1	**10,043%**
Giao dịch (trx)	38.764.930	15	342.181	9	**0,883%**
Vị trí (geo)	66.295.724	6	0	0	**0,000%**
Hội thoại (dialog)	217.205	4	0	0	**0,000%**

Đã kiểm tra unique và duplicate trên toàn dữ liệu; giữ nguyên các dòng gốc.

Nhóm biến hành vi hiện có

16 trường thuộc tính sự kiện · đã tách ID, thời gian và fold

GIAO DỊCH

12

thuộc tính sự kiện

1 amount

11 mã loại, tiền tệ, nguồn/đích

VỊ TRÍ

3

mã vị trí

geohash_4

geohash_5 · geohash_6

HỘI THOẠI

1

cột embedding

Vector 768 chiều

Không có văn bản gốc trong bảng

16
thuộc tính hành vi

14
ID / thời gian / fold

4
nhãn target

2
cột phụ trợ nhãn

768 chiều nằm trong 1 cột embedding.

Các biến trong bảng khách hàng, nhãn và giao dịch

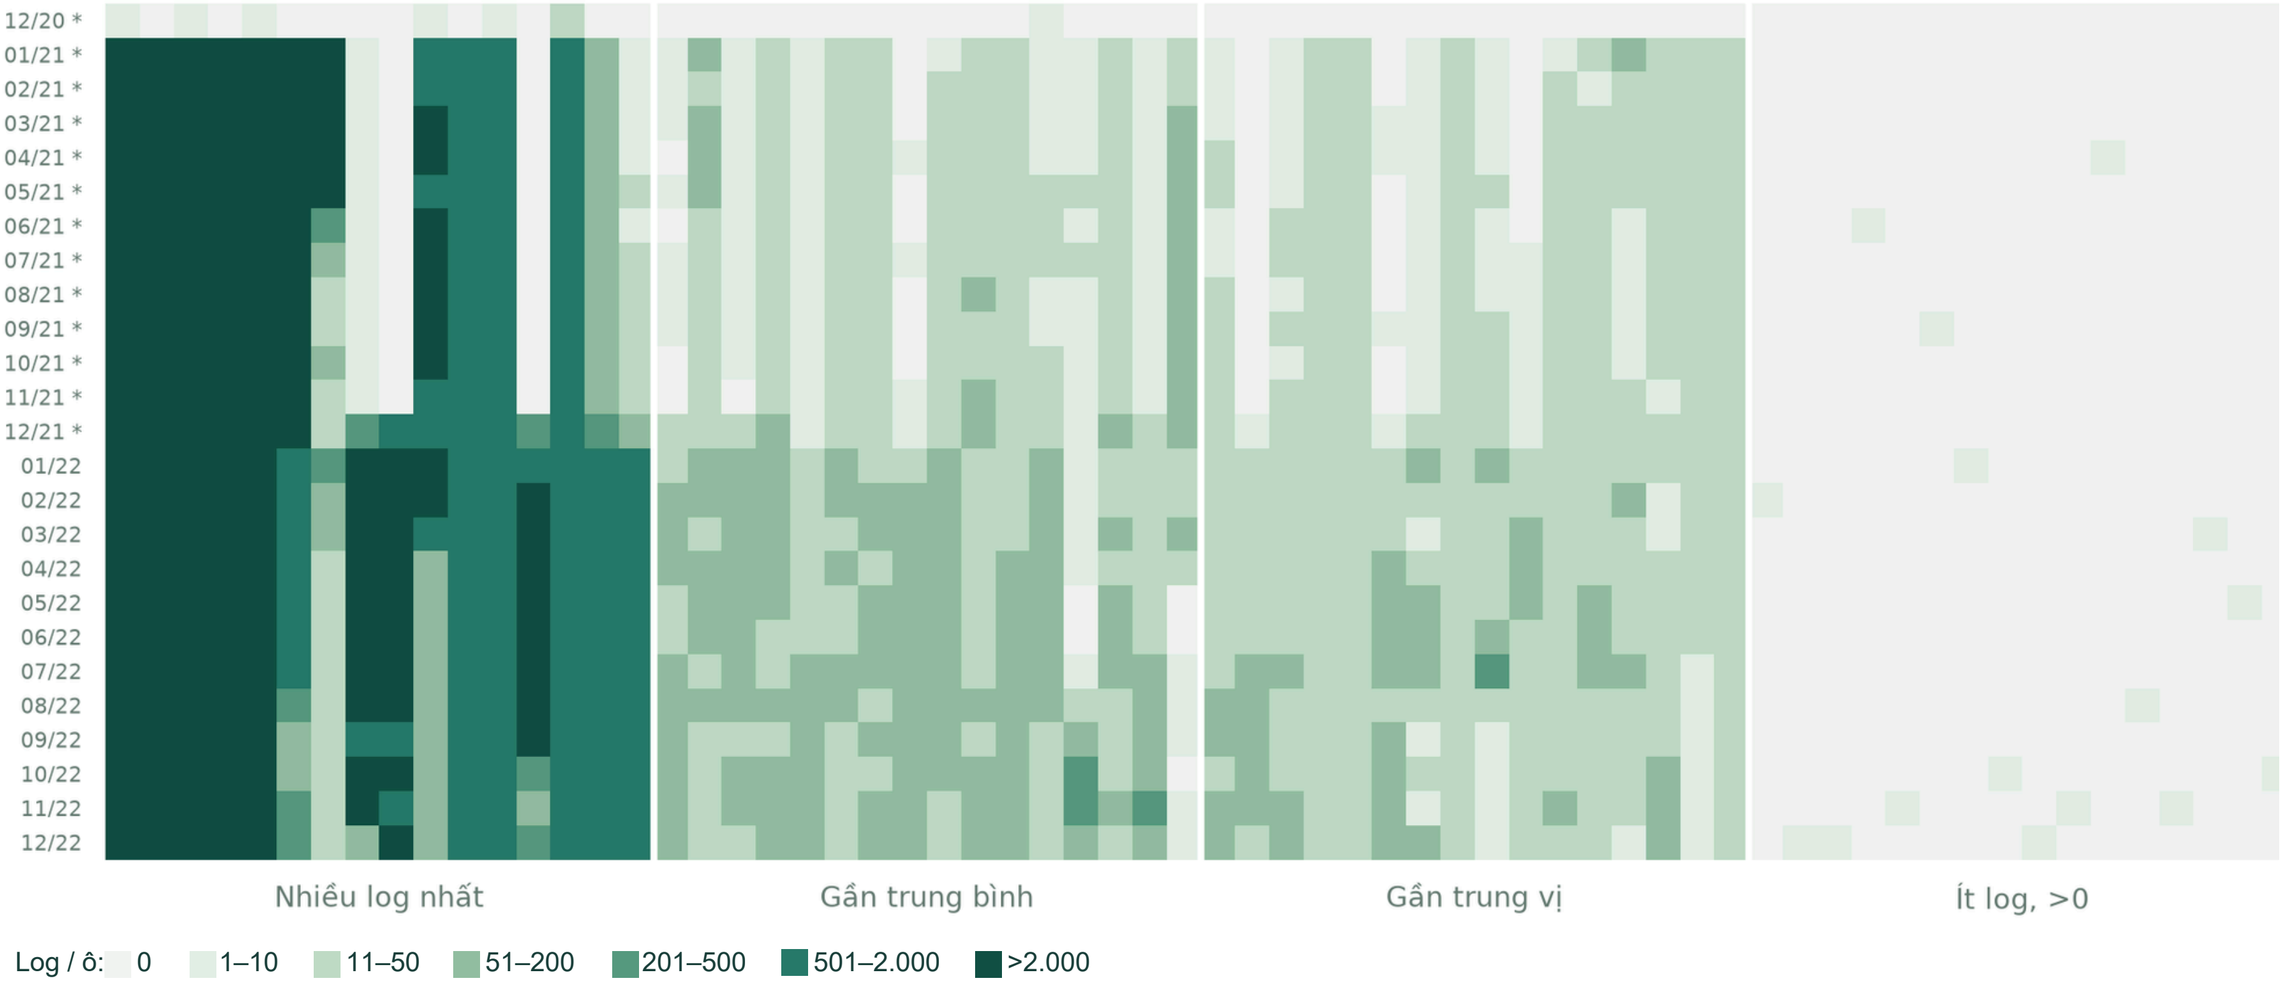
Bảng	Biến	Nội dung và cách diễn giải
client_split	client_id; fold	Mã khách hàng và nhóm chia dữ liệu
targets	client_id; mon; fold	Khóa khách hàng - tháng và phân chia dữ liệu
targets	target_1; target_2; target_3; target_4	Bốn nhãn nhị phân. Chưa xác định tên sản phẩm nghiệp vụ
targets	trans_count; diff_trans_date	Trường phụ trợ liên quan giao dịch. Chưa xác minh đầy đủ công thức, đơn vị và thời điểm tạo
detail/trx	client_id; event_time; fold	Khách hàng, thời điểm sự kiện và phân chia dữ liệu
detail/trx	amount	Số thực float32 như lưu trong dữ liệu gốc. Chưa xác nhận đơn vị hoặc phép biến đổi trước khi công bố
detail/trx	event_type; event_subtype; currency	Mã loại giao dịch, loại phụ và tiền tệ đã mã hóa
detail/trx	src_type11; src_type12; dst_type11; dst_type12	Các cặp thuộc tính phía nguồn và phía đích đã mã hóa
detail/trx	src_type21; src_type22; src_type31; src_type32	Các thuộc tính nguồn bổ sung đã mã hóa

Dữ liệu vị trí, hội thoại

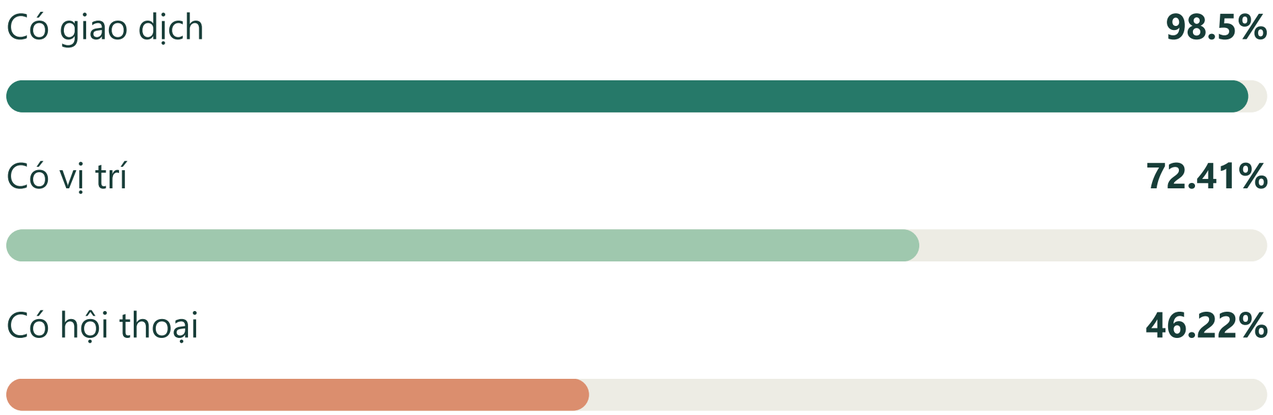
Bảng	Biến	Nội dung
detail/geo	client_id; event_time; geohash_4; geohash_5; geohash_6; fold	Sự kiện vị trí với ba cấp mã vị trí
detail/dialog	client_id; event_time; embedding; fold	Vector float32 có 768 chiều, không cung cấp văn bản hội thoại gốc
ptls/trx; ptls/geo; ptls/dialog	Các biến tương ứng của detail tổ chức thành mảng. client_id và fold vẫn ở cấp khách	event_time ở ptls có kiểu int64

Độ phủ hành vi trong lịch sử 12 tháng

01–12/2022 · Cutoff 01/01/2023 · 4 nhóm × 10 khách hàng không trùng nhau



Lượng khách hàng có hành vi



468

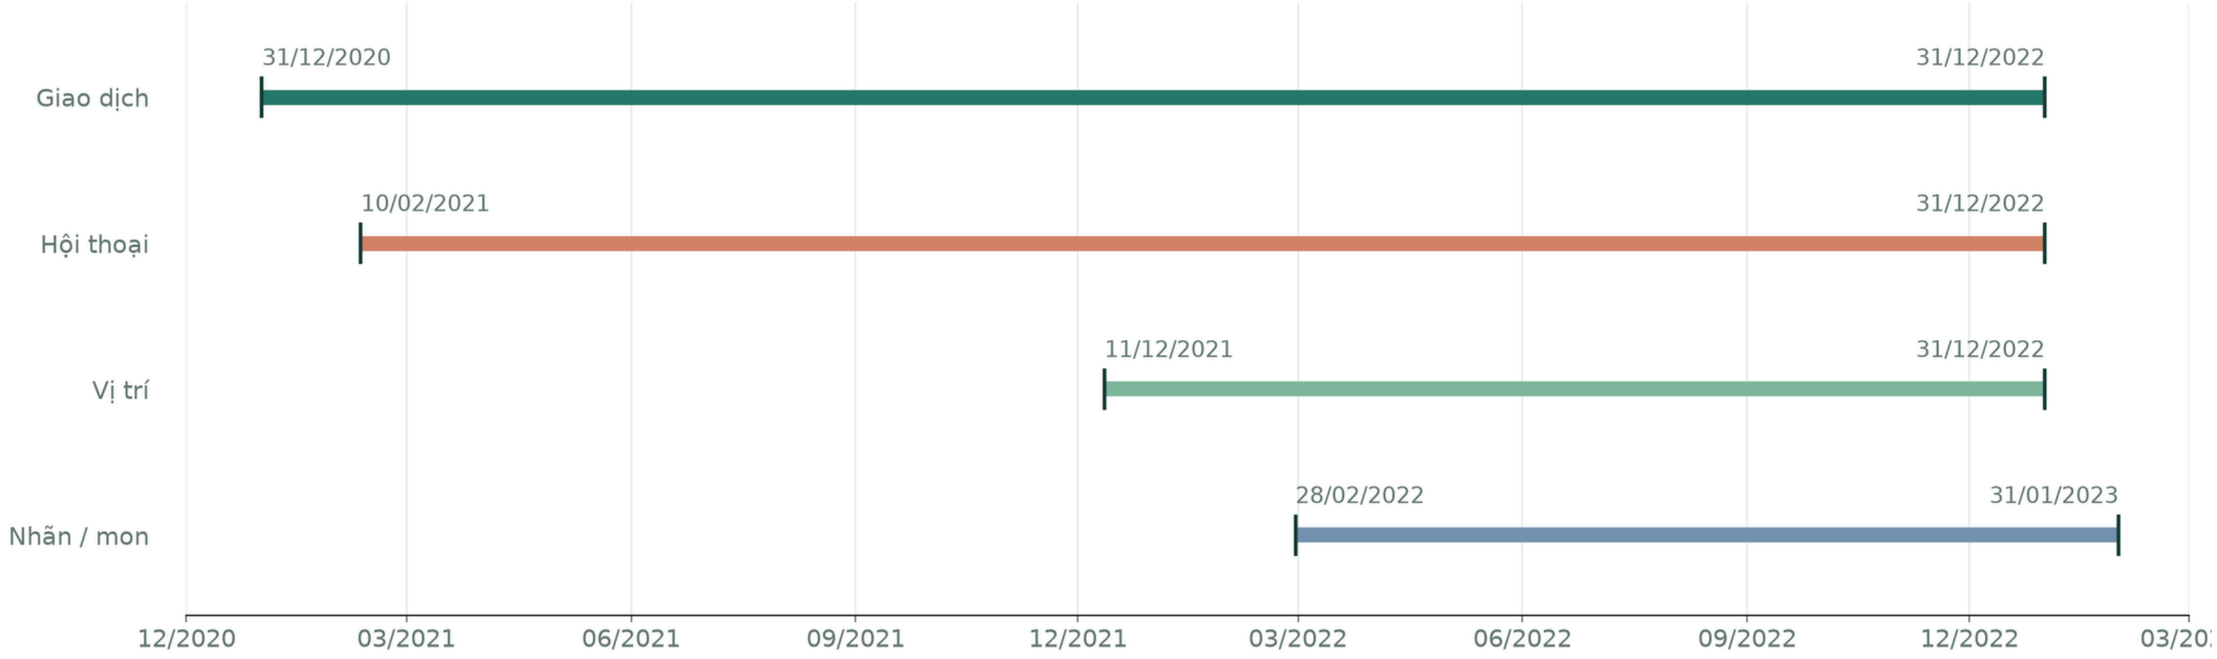
khách không có log ở cả ba nguồn.

Thiếu nguồn cần trở thành thông tin cho mô hình.

Nguồn: customer_activity.csv · source_count_distribution.csv

Các nguồn bắt đầu ở các thời điểm khác nhau

Độ dài đoạn theo thời gian thực · vạch thẳng đánh dấu hai đầu

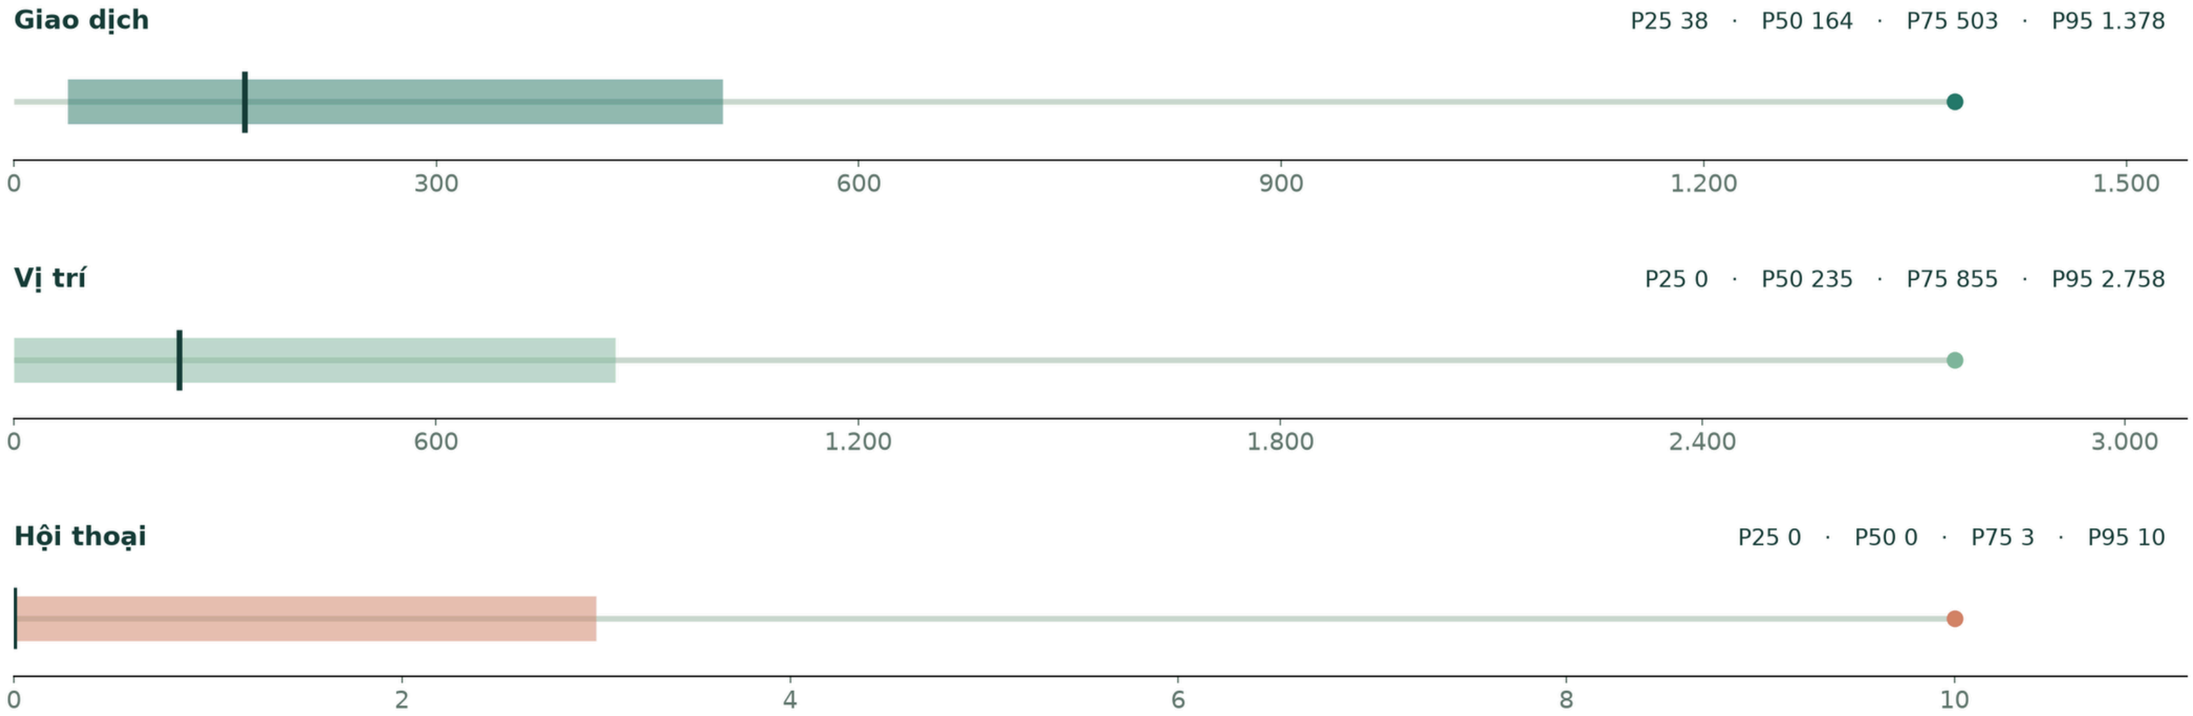


Đoạn thể hiện khoảng min–max timestamp quan sát; không khẳng định có log liên tục cho mọi khách.

Nguồn: source_time_ranges.csv · label_coverage.csv

Phân vị số log trên mỗi khách

Toàn lịch sử · 100.224 khách, gồm cả khách có 0 log



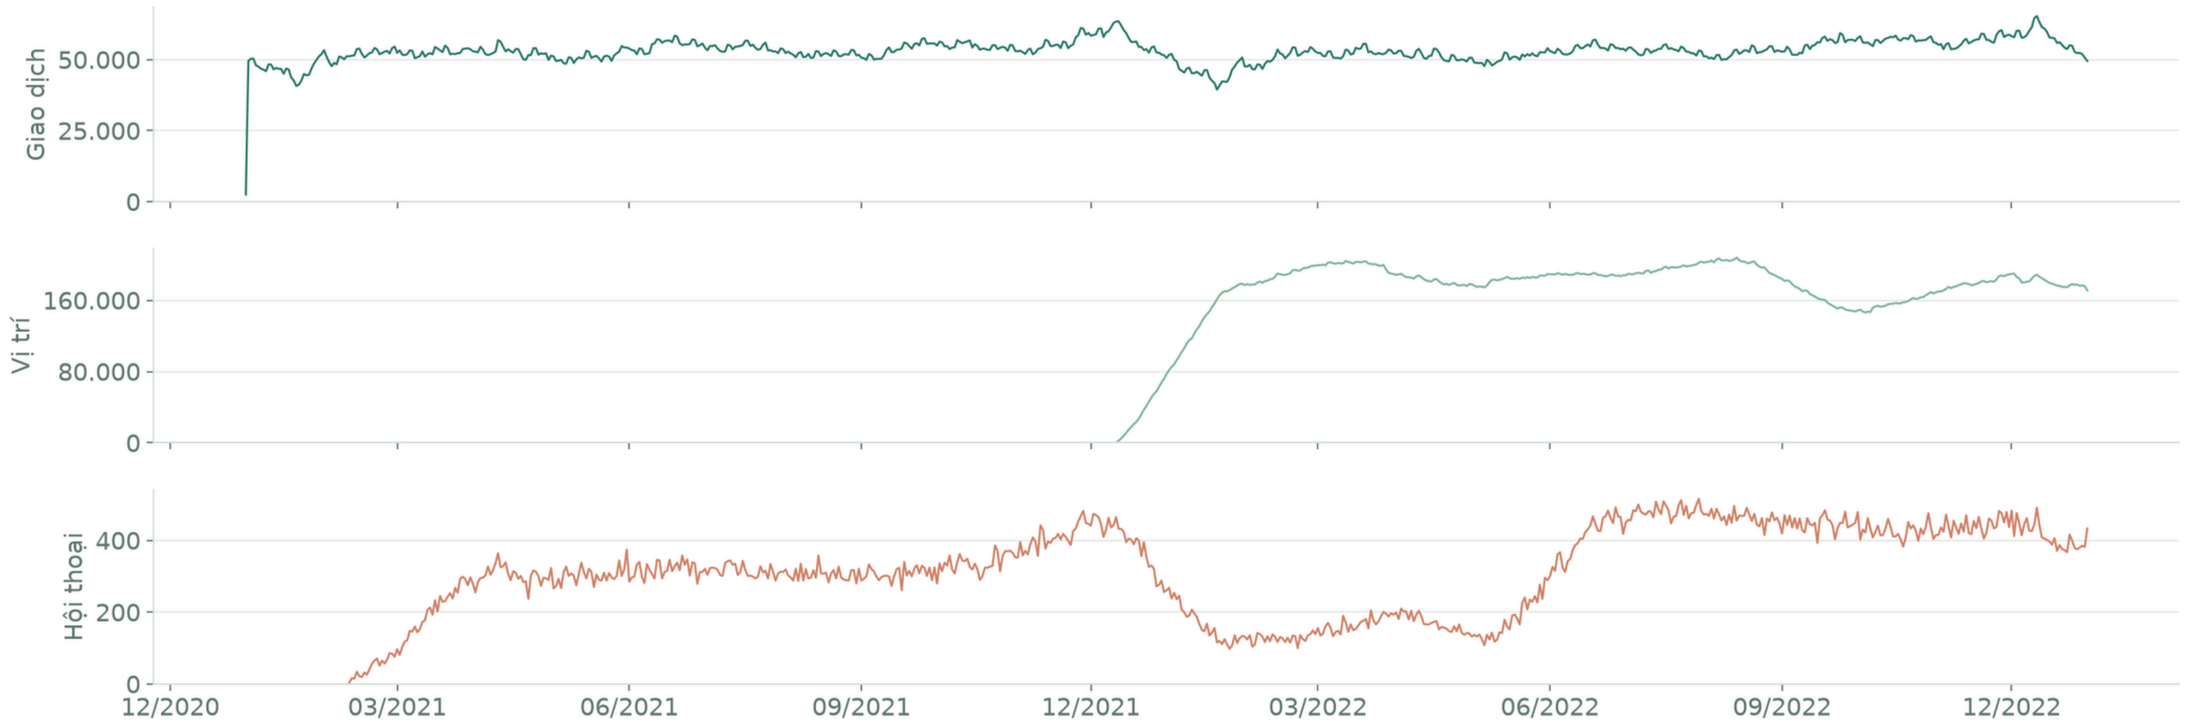
Dải màu P25–P75 · vạch P50 (trung vị) · chấm P95 · trục tuyến tính riêng từng nguồn.

trx: TB 386,78, max 1.020.773 · geo: TB 661,48, max 39.487 · dialog: TB 2,17, max 114

Nguồn: review/events_per_customer.csv

Số log được ghi nhận theo ngày

Toàn lịch sử · 3 nguồn, trục Y riêng · số dòng sự kiện / ngày



Mỗi điểm là số log quan sát trong một ngày; phần chưa có nguồn không được diễn giải là không hoạt động.

Nguồn: review/daily_behavior.csv · tổng 105.277.859 log

Các quan sát cực trị về tần suất hành vi

Sử dụng hàng rào Tukey: [Q1 - 1,5 x IQR; Q3 + 1,5 x IQR], với IQR = Q3 - Q1. Cờ thống kê xác định điểm cần đối chiếu, không tự xác nhận lỗi dữ liệu.

Nguồn	Ngưỡng trên / khách	Khách vượt IQR	Khách trên P99	Max / khách
trx	1.200,5	6.952	1.003	1.020.773
geo	2.137,5	8.171	1.003	39.487
dialog	7,5	8.007	892	114
any_source	3.265,0	5.390	1.002	1.021.115

Cực trị số log theo ngày trong khoảng đã ghi nhận của nguồn

Nguồn	Ngày trong phạm vi	Ngày vượt IQR	Ngày có nhiều log nhất	Max log / ngày
trx	731	15	2022-12-11	65.302
geo	386	0	2022-08-14	207.845
dialog	690	0	2022-07-30	516

Các phân phối theo khách giữ cả khách 0 log. Đối với hội thoại thưa, IQR nhỏ có thể gắn cờ nhiều khách. Báo cáo giữ toàn bộ quan sát và so sánh thêm P99 cùng bối cảnh sự kiện.

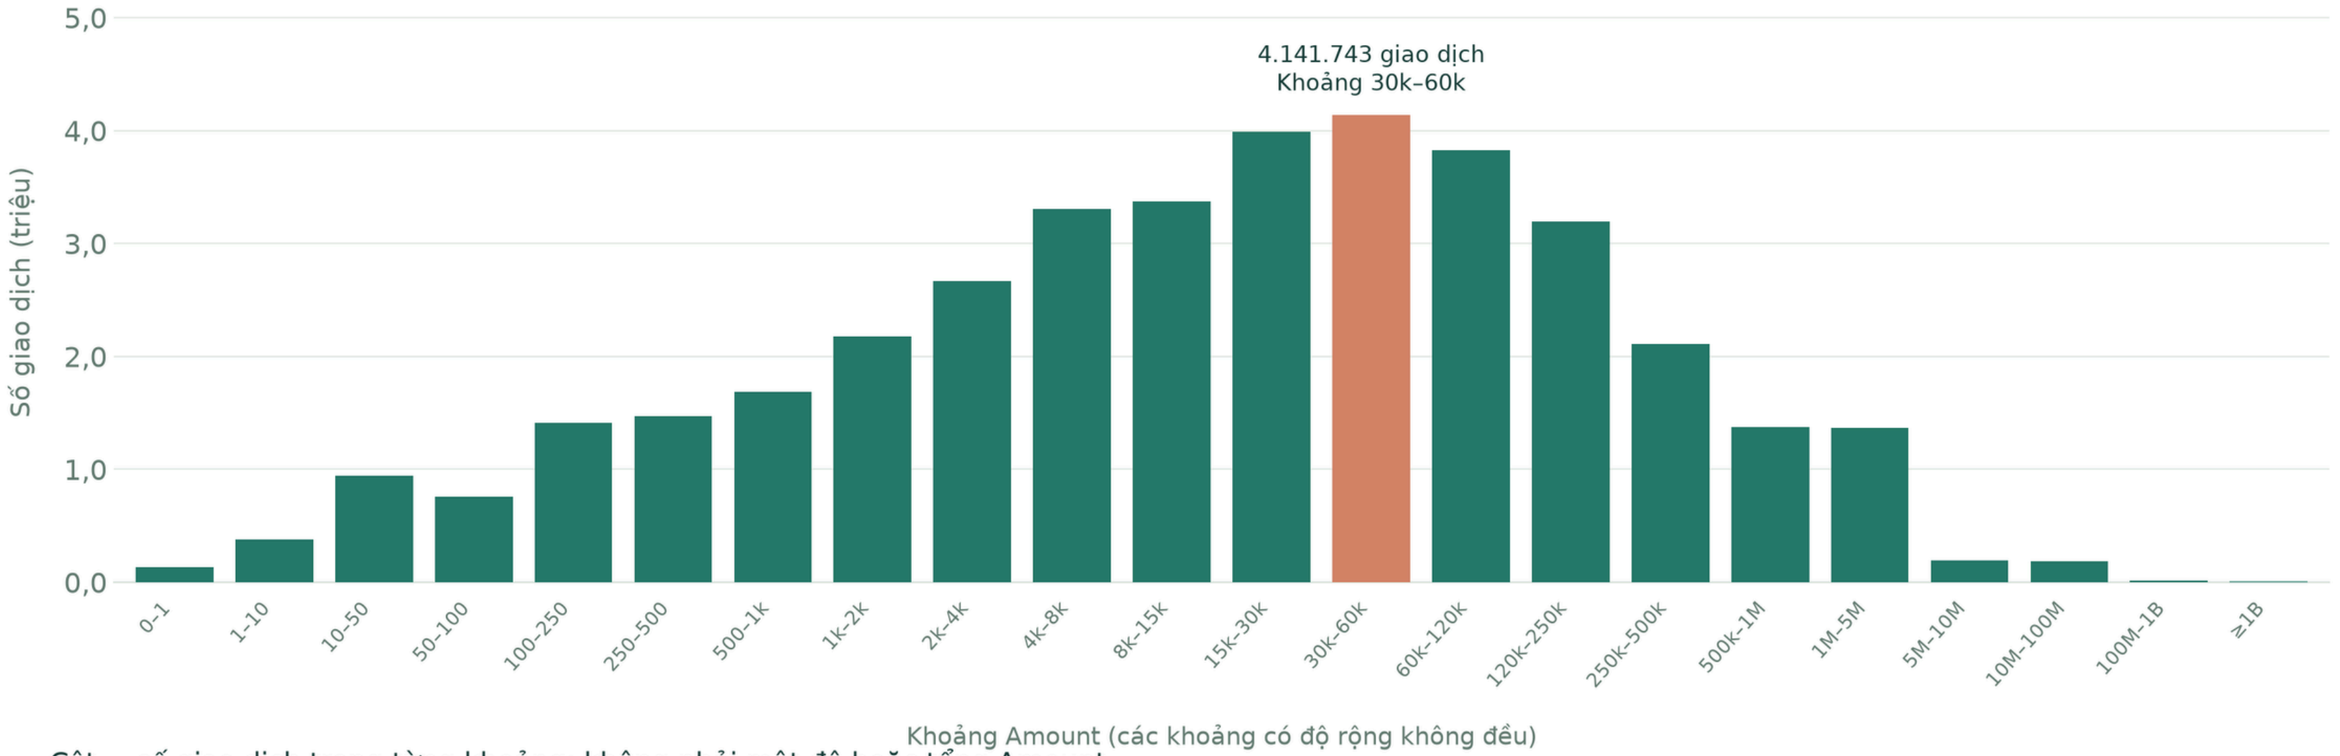
Giá trị ngoại lai của Amount theo từng mã currency

Currency	số lượng amount	Hàng rào Tukey trên	Ngoài hàng rào IQR	Max Amount
1	159	581.374,25	34	20.282.912
10	199	3.463.201,08	31	240.265.824
11	38.724.240	232.726,99	5.521.385	1.370.187.366.400
12	4	112.854.829,05	1	165.288.160
15	16.041	13.217.135,27	2.287	15.276.779.520
16	7	27.919,19	1	8.901.813
17	446	731.018,21	84	200.437.408
3	20.324	7.325.330,44	2.893	11.413.068.800
4	3.128	5.396.561,34	522	1.716.621.056
5	6	59.846.694,49	0	30.751.148
6	82	32.242.501,10	10	570.385.536
8	174	121.353,43	31	22.350.060
9	2	2.686.606,67	0	1.792.952
null	118	1.333.081,07	20	17.886.422

Phân phối Amount · currency = 11

Toàn lịch sử · 38.724.240 giao dịch · giá trị gốc, không log

Trung vị	P95	P99
18.025,02	896.744,64	5.257.531,79



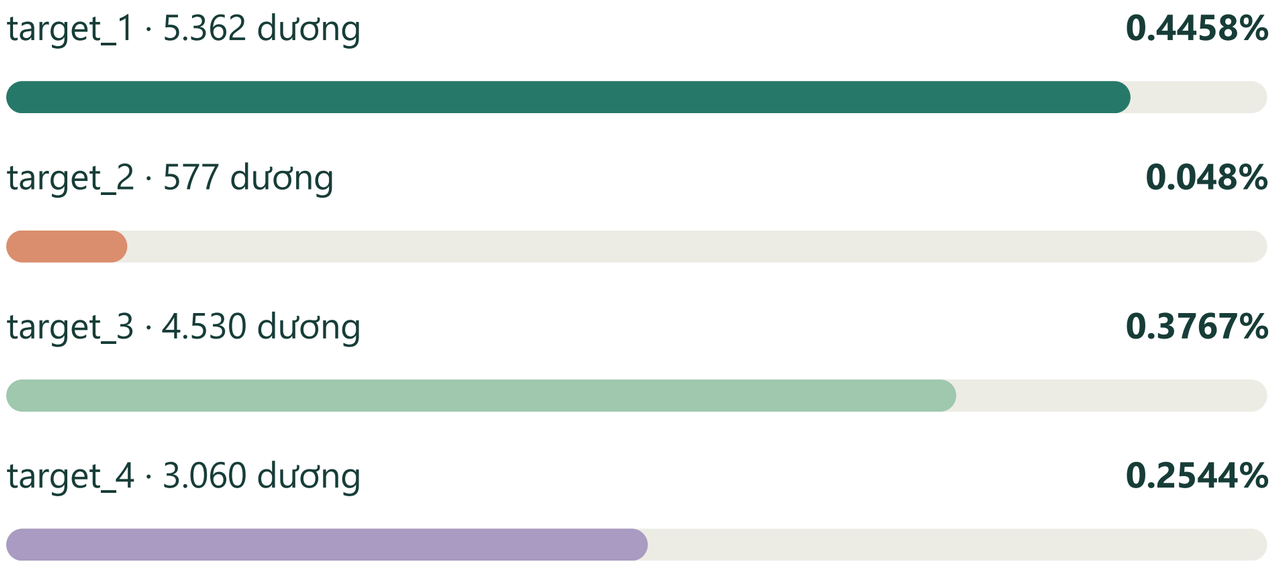
Cột = số giao dịch trong từng khoảng; không phải mật độ hoặc tổng Amount.

Giữ toàn bộ phần đuôi trong khoảng cuối. k = 1.000; M = 1 triệu; B = 1 tỷ đơn vị Amount gốc.

Chưa xác minh mã 11 tương ứng đồng tiền nào; không quy đổi hoặc gắn đơn vị VND/USD.

NHÃN HIẾM

Mỗi sản phẩm chỉ có một phần rất nhỏ mẫu dương.



≈1.069%

cho phát sinh ít nhất 1 target

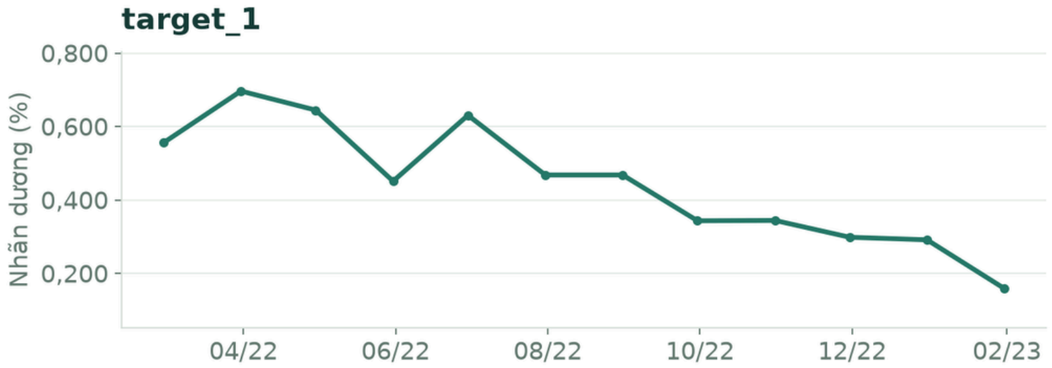
Đơn vị: khách hàng–tháng.

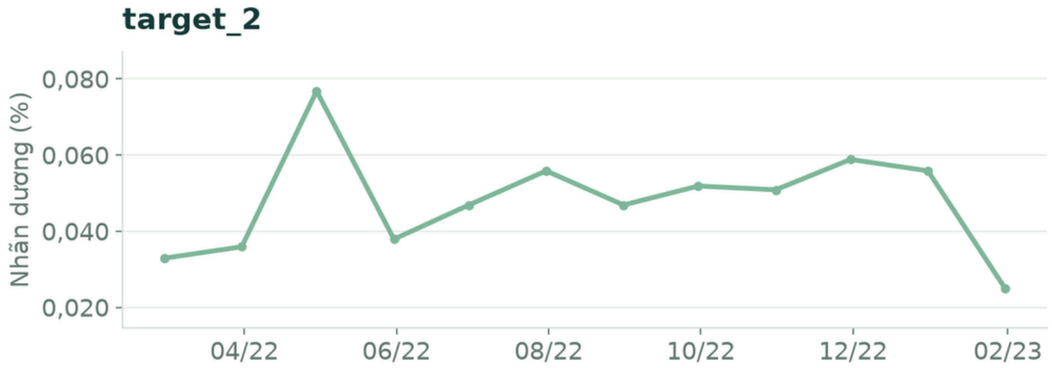
Không dùng accuracy làm thước đo chính.

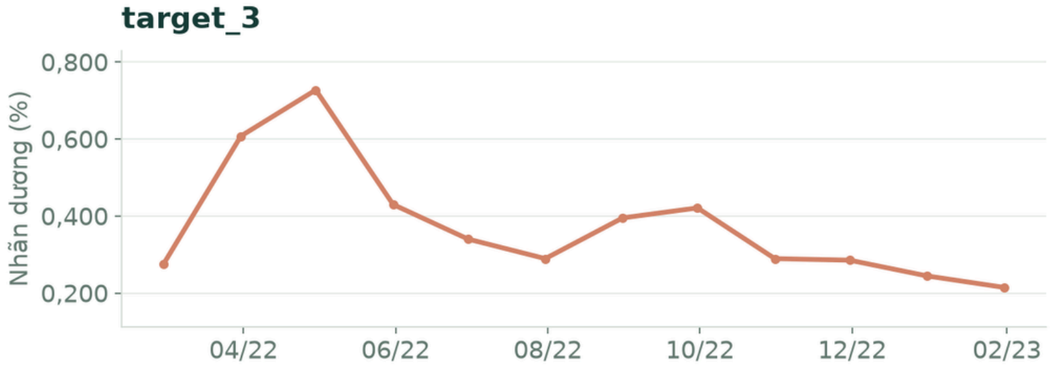
Nguồn: target_prevalence.csv · mẫu số mỗi nhãn: 1.202.688 dòng

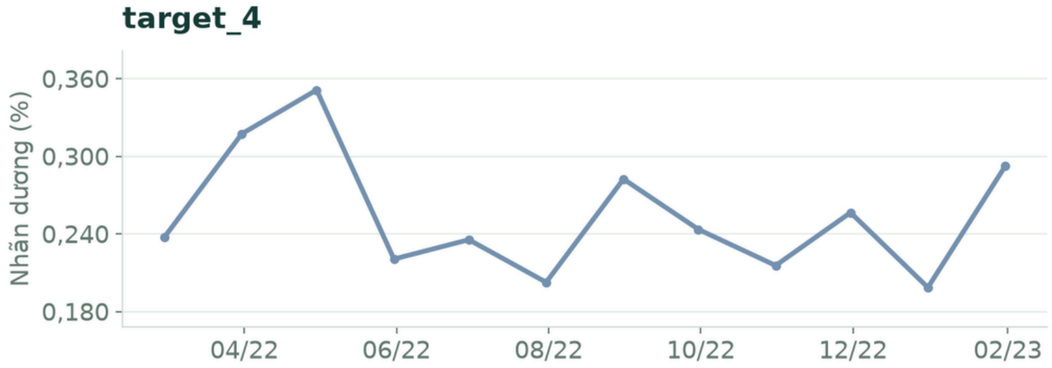
Biến động tỷ lệ nhãn dương theo tháng

4 biểu đồ trên cùng trang · mỗi target có thang Y riêng









Y: % khách–tháng có nhãn dương · mỗi tháng 100.224 dòng · trục Y đã zoom và có thể không bắt đầu từ 0.

THIẾT KẾ ĐÁNH GIÁ

Giữ tháng cuối để kiểm thử. Đo chất lượng xếp hạng.

ĐỀ XUẤT CHIA THEO THỜI GIAN

Train → Validation → Test

Các tháng trước → tháng gần cuối → 01/2023

AP / PR-AUC

Precision@K

Recall@K · Lift@K

So sánh giao dịch → + vị trí → + hội thoại.

675

khách mua tháng cuối

0,6735% trong 100.224 khách.

target_2 chỉ có 25 khách dương.

Nguồn: last_month_purchase/assessment.md · chia tập & ablation là đề xuất

KẾT LUẬN & NGUỒN

Đủ cơ sở để thử propensity. Chưa đủ để hứa hiệu quả.

Dữ liệu

Quy mô lớn · liên kết được theo khách–tháng

Thách thức

Nhãn hiếm · nguồn lệch thời gian · thiếu modality

Hướng đi

Baseline theo thời gian → kiểm chứng giá trị đa nguồn