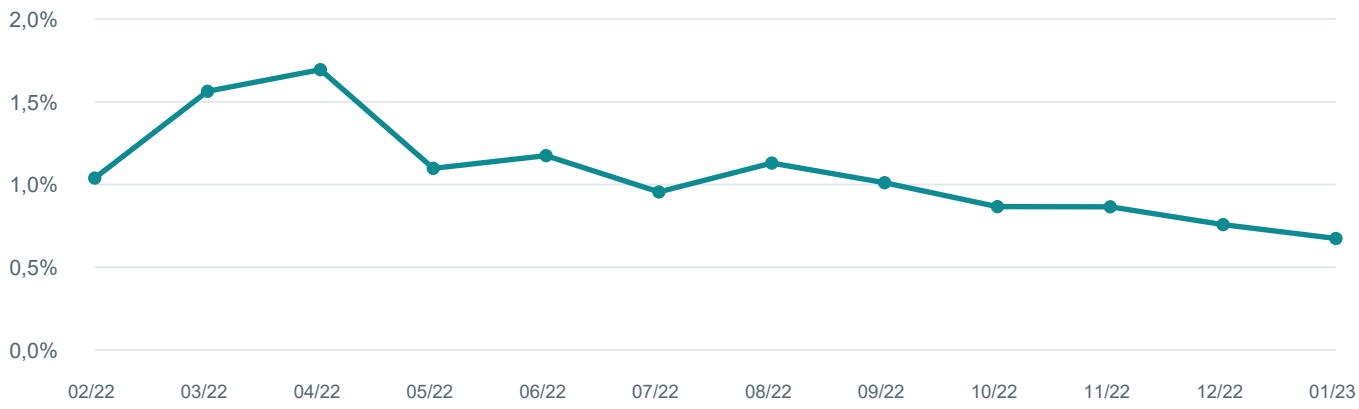
EDA MBD-mini

MBD-mini / Nghiên cứu propensity

100.224	1.202.688	221
khách hàng	dòng khách-tháng	đặc trưng

Nhãn đầy đủ, tỷ lệ mua chỉ 1,0688%

Mục tiêu **y_any** là mua ít nhất một trong bốn sản phẩm trong tháng đích. Có **12.854** dòng dương trong **1.202.688** dòng nhãn. Tỷ lệ theo tháng từ **0,673%** đến **1,694%**. Cần đánh giá bằng AP/PR-AUC và Precision, Recall, Lift theo ngân sách.



Tỷ lệ nhãn dương theo tháng, toàn bộ cohort

Quy mô ba nguồn sự kiện

Giao dịch	**38.764.930**	sự kiện
Vị trí	**66.295.724**	sự kiện
Hội thoại	**217.205**	sự kiện

Phạm vi: raw toàn lịch sử ở 8 bảng. Thống kê đặc trưng và liên hệ nhãn chỉ dùng **701.568 dòng train 02-08/2022**. Detail là sự kiện, PTLS là chuỗi tương ứng và không cộng hai dạng.

Nguồn: overview.csv, target_monthly.csv, manifest.json. Báo cáo kỹ thuật kèm 12 biểu đồ và 57 bảng CSV.

Chất lượng dữ liệu và ngoại lai

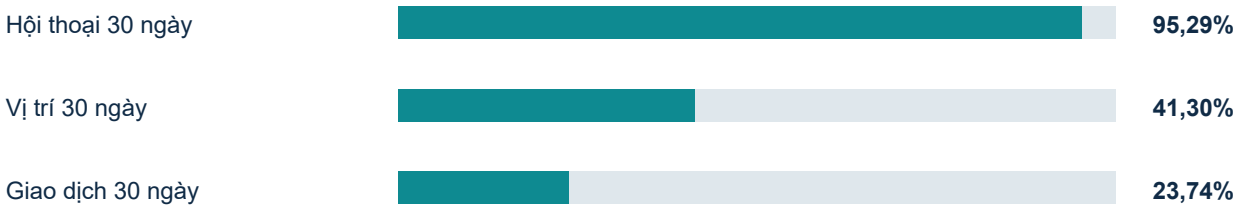
MBD-mini / Nghiên cứu propensity

0
dòng raw trùng hoàn toàn

54
đặc trưng có giá trị thiếu

40
đặc trưng hằng quan sát

Tỷ lệ thiếu recency trong cửa sổ 30 ngày



Giữ khách thiếu nguồn. Thêm cờ missing/coverage và chỉ fit imputation trên train khi thuật toán cần. **diff_trans_date** thiếu 120.786 dòng (10,043%), đều có trans_count=0. Đây là thiếu thuộc tính phụ trợ, không phải mất nhãn.

Amount theo currency mã 11

Số giao dịch	**38.724.240**
Trung vị (đơn vị dữ liệu)	**18.025,023**
IQR gốc (đối chiếu)	**5.521.385 dòng / 14,2582%**
Log1p-IQR (kết quả chính)	**584.139 dòng / 1,5085%**

Tính log trước quartile, xét cả hai đuôi: 486.868 dòng thấp và 97.271 dòng cao. ln(amount) cho 1,5861% ngoài hàng rào. **Giữ raw, không tự động xóa/cap.** Không kết luận cho IQR log=0, nhóm dưới 30 giá trị hoặc currency thiếu. Không gộp amount khác currency.

Đối soát biểu diễn: PTLS/trx ít hơn detail/trx **2.020.020 sự kiện**. Có một cặp giao dịch cùng khách/timestamp nhưng khác thuộc tính, được giữ lại. Dùng detail làm lịch sử giao dịch đầy đủ.

Nguồn: feature_statistics_train.csv, missing_diff_context.csv, duplicates.csv, amount_outliers_by_currency.csv, detail_sequence_reconciliation.csv.

Đặc trưng và bước tiếp theo

Liên hệ mạnh nhất với y_any trong train



Pearson dùng toàn bộ train. Liên hệ đơn biến còn thấp và không phải feature importance hay nhân quả. Mẫu 30.000 dòng có **259 cặp |r| >= 0,90**, cần kiểm tra dư thừa.

Ưu tiên triển khai

Thiếu nguồn. Giữ NaN, thêm cờ missing và coverage.

Số đếm và amount. Log1p/signed-log, tách currency; scaling khi cần.

Mã phân loại. Encoding phù hợp, có nhóm unknown riêng.

Biến hằng / tương quan cao. Rà soát trên train và kiểm chứng qua validation.

Tránh leakage: event_time < cutoff. Loại client_id, fold, nhãn, trans_count và diff_trans_date khỏi predictor. Fit mọi bước imputation/encoding/scaling trên train.

Lịch đánh giá theo thời gian

Train	Validation	Calibration	Test khóa
02-08/2022	09-11/2022	12/2022	01/2023

Giới hạn: khách lặp qua tháng nên quan sát không độc lập. Một số biểu đồ, Spearman và ma trận nhiều biến dùng mẫu hash 30.000 dòng, seed 42; tỷ lệ thiếu, Pearson với nhãn và số đếm outlier dùng toàn bộ phạm vi tương ứng. Báo cáo này không huấn luyện mô hình, không đánh giá test và không suy ra ROI chiến dịch.

Nguồn: feature_target_associations.csv, high_correlation_pairs.csv, feature_engineering_plan.csv. Chi tiết, định nghĩa và bảng đầy đủ: deliverables/eda/report.html và notebooks/eda.ipynb.