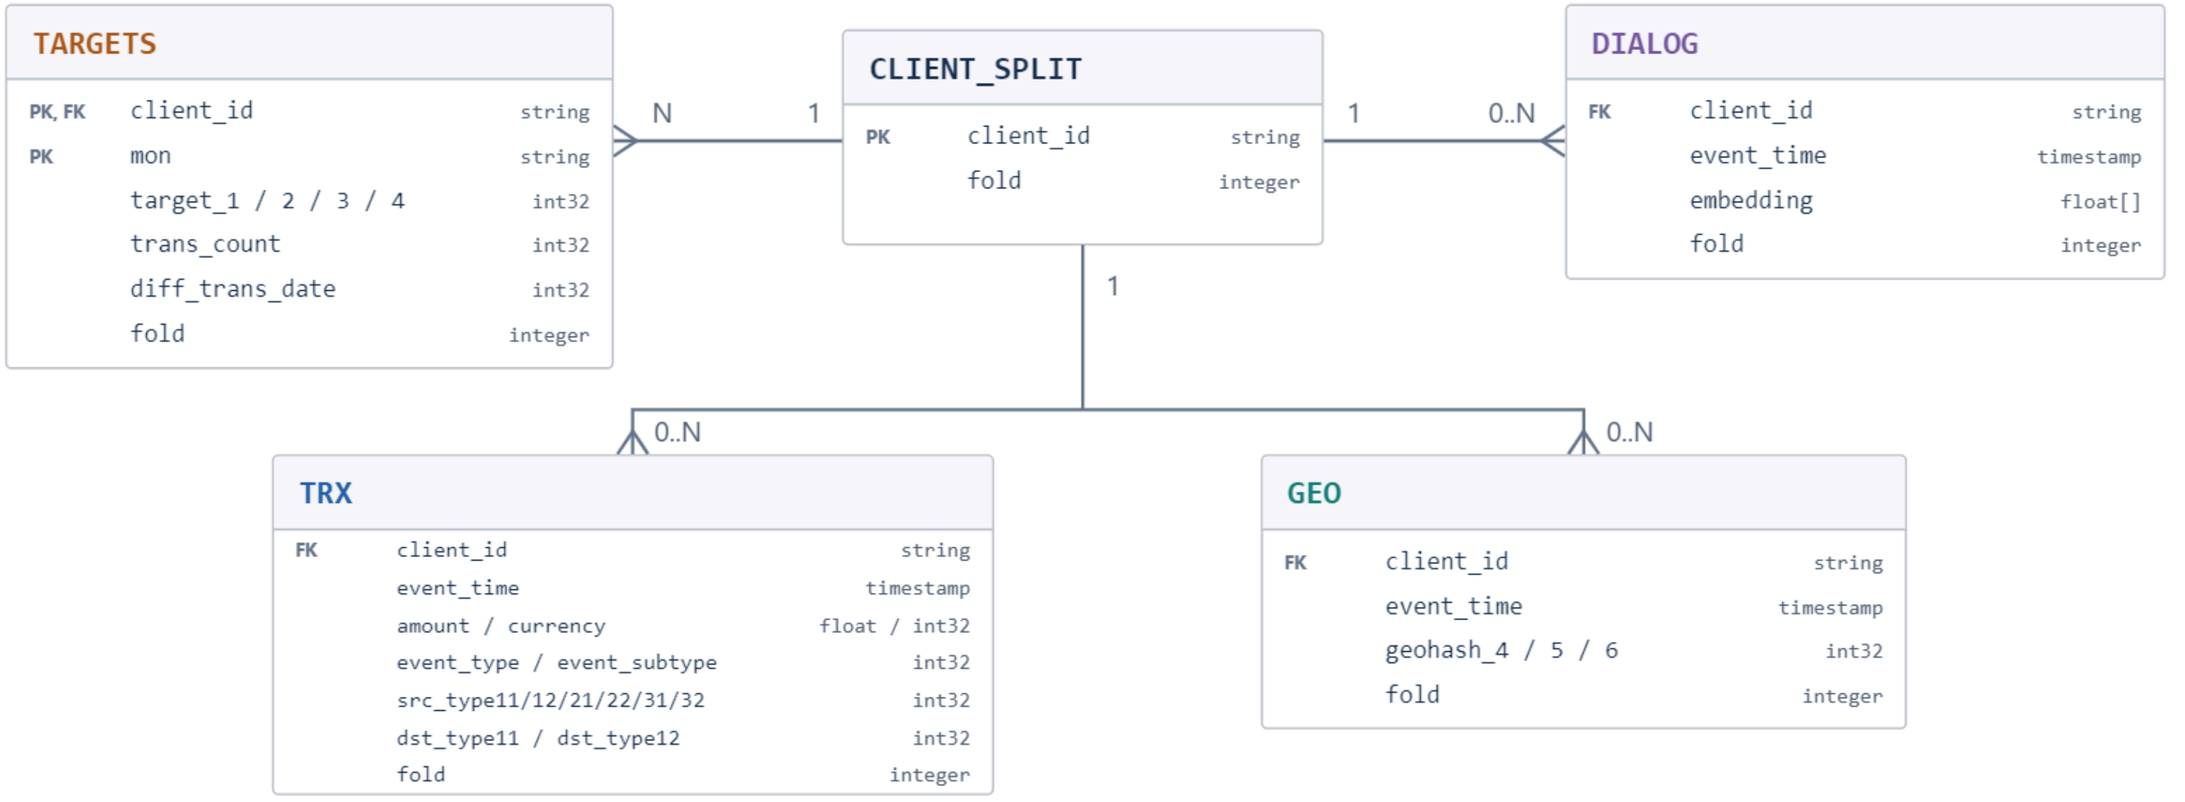
Multumodal dataset banking

MBD mini

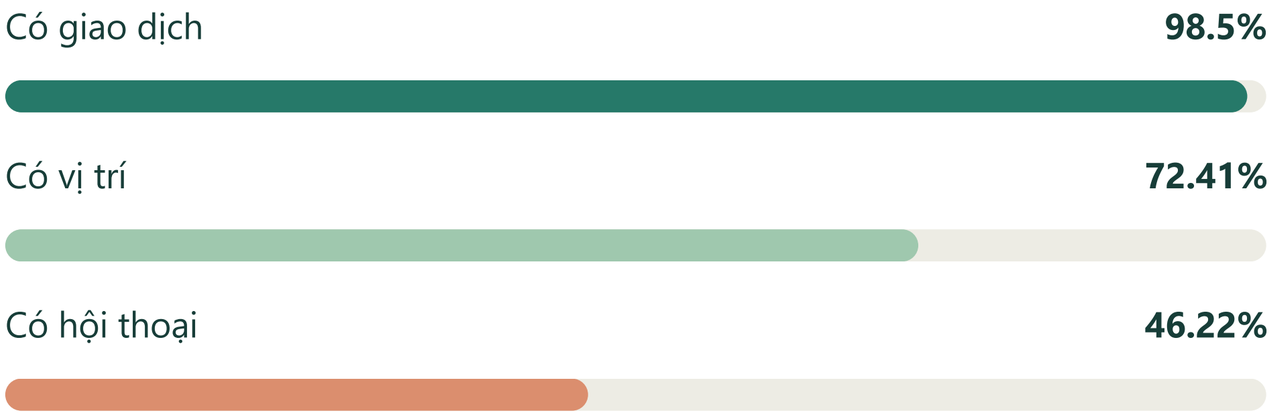
Dataset Understanding & Exploratory Data Analysis

Hiểu cấu trúc dữ liệu, hành vi quan sát được
và giới hạn diễn giải

ERD DATABASE



Lượng khách hàng có hành vi

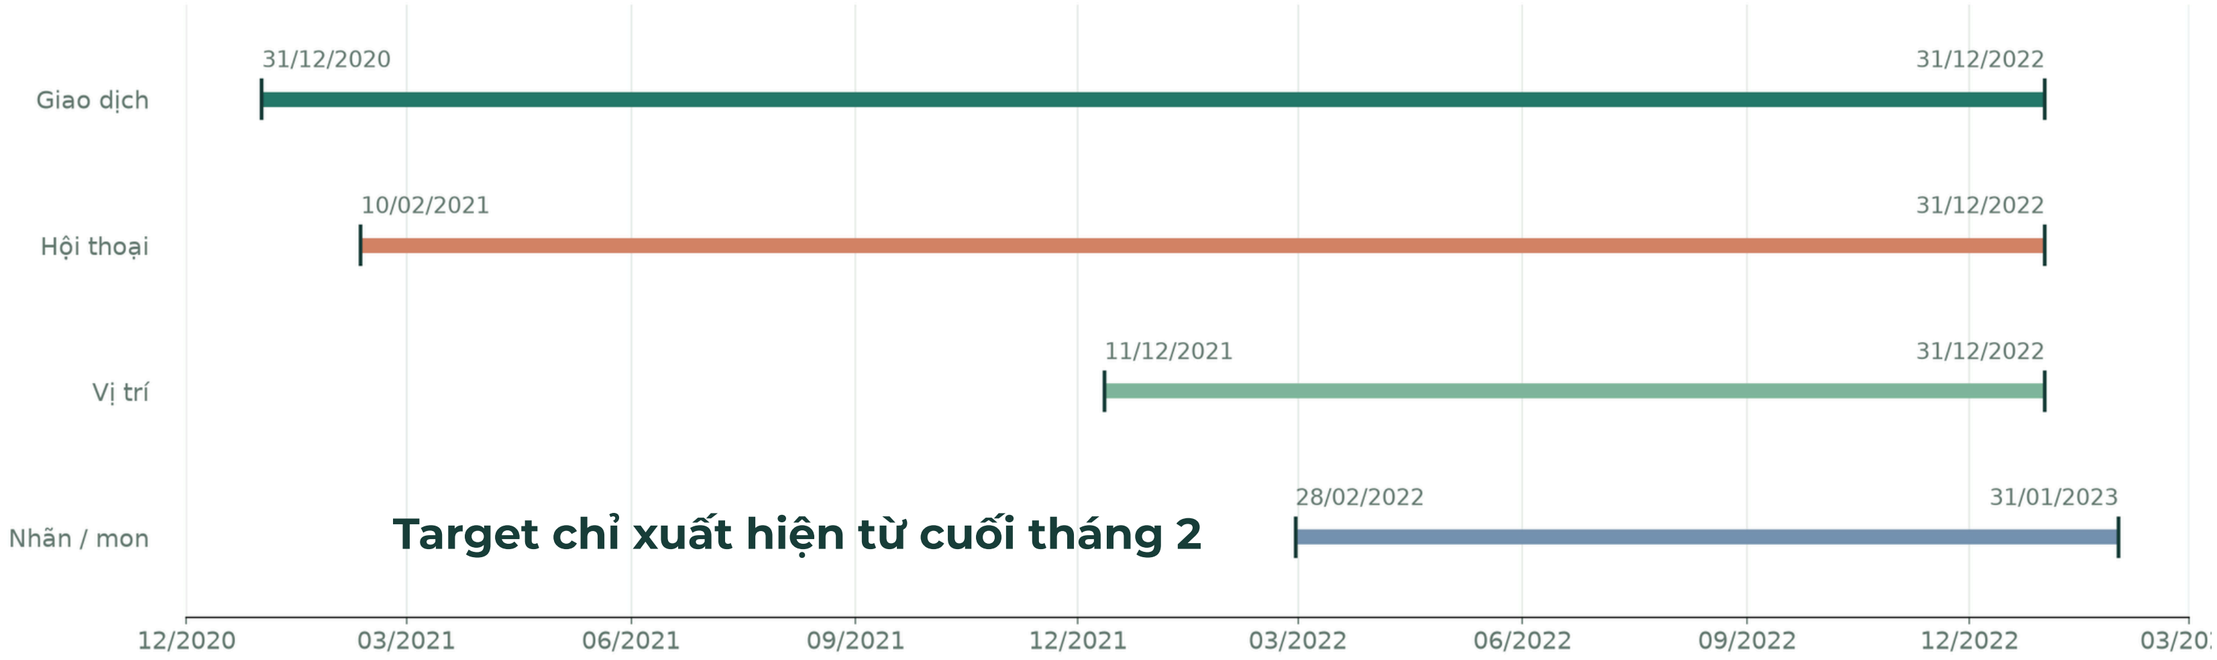


Trong **1.503** khách không có trx:

- Có geo hoặc dialog: **1.035** khách (**1,03%**)
- Không có cả 3 log: **468** khách (**0,47%**)

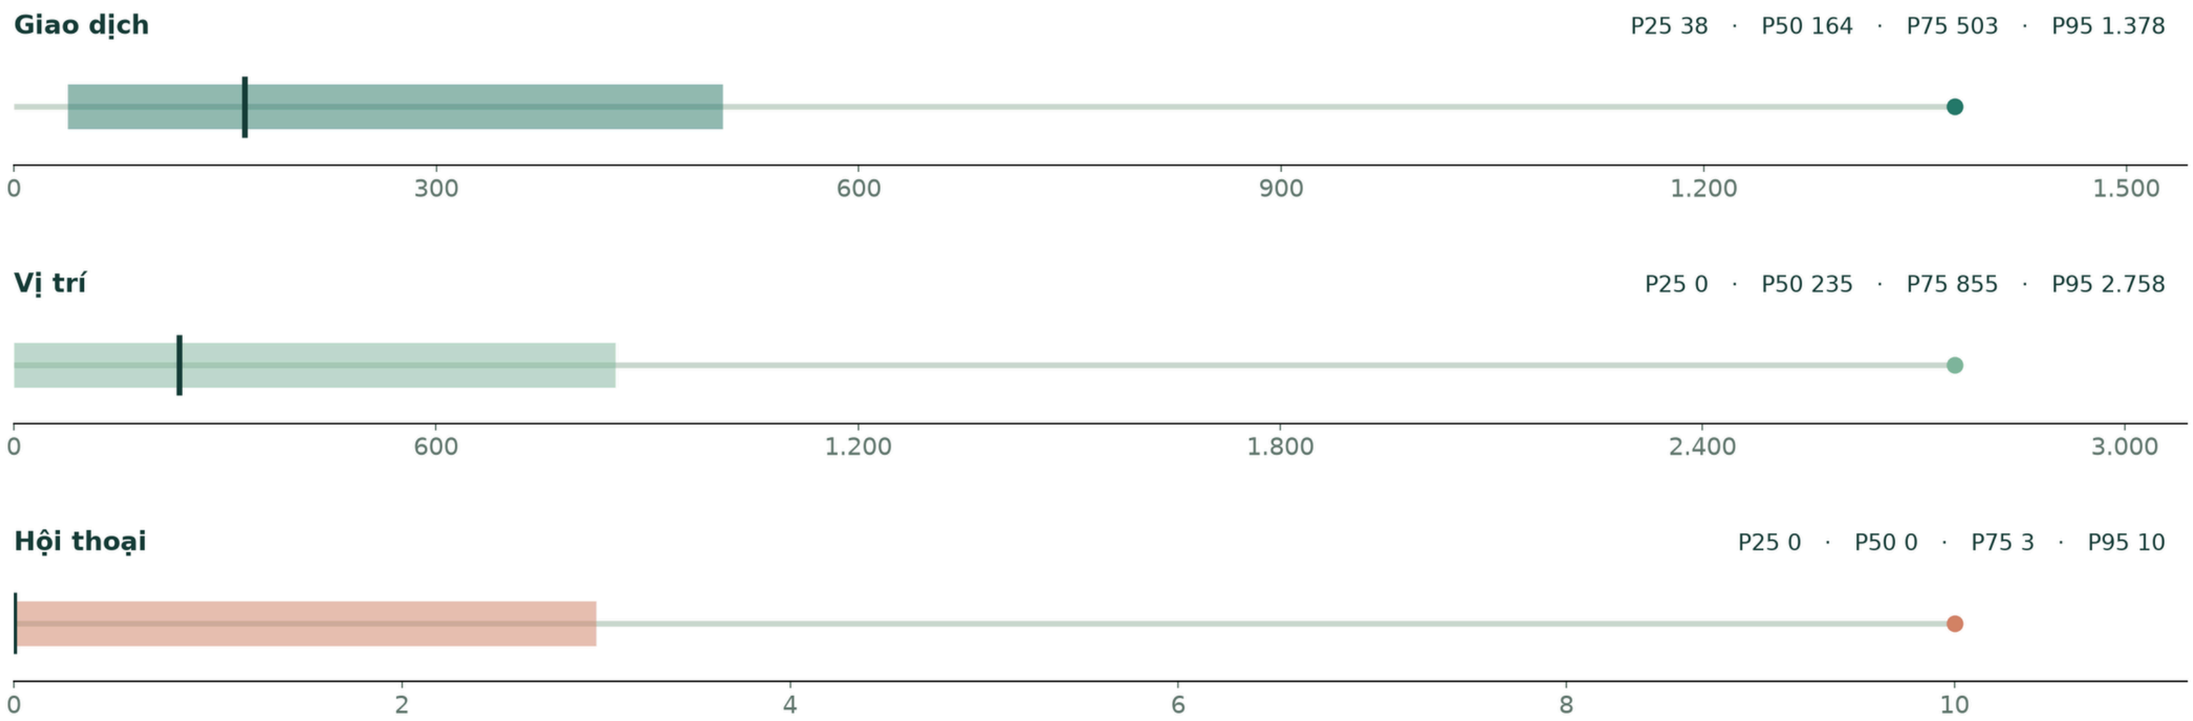
Thiếu nguồn cần trở thành thông tin cho mô hình.

Các nguồn bắt đầu ở các thời điểm khác nhau



Phân vị số log trên mỗi khách

Toàn lịch sử · 100.224 khách, gồm cả khách có 0 log



trx: TB 386,78, max 1.020.773 · geo: TB 661,48, max 39.487 · dialog: TB 2,17, max 114

TARGET

Ghi nhận sử dụng sản phẩm của ngân hàng

Target	Sản phẩm tương ứng
Target_1	Business card
Target_2	Credit
Target_3	Salary project
Target_4	Acquiring

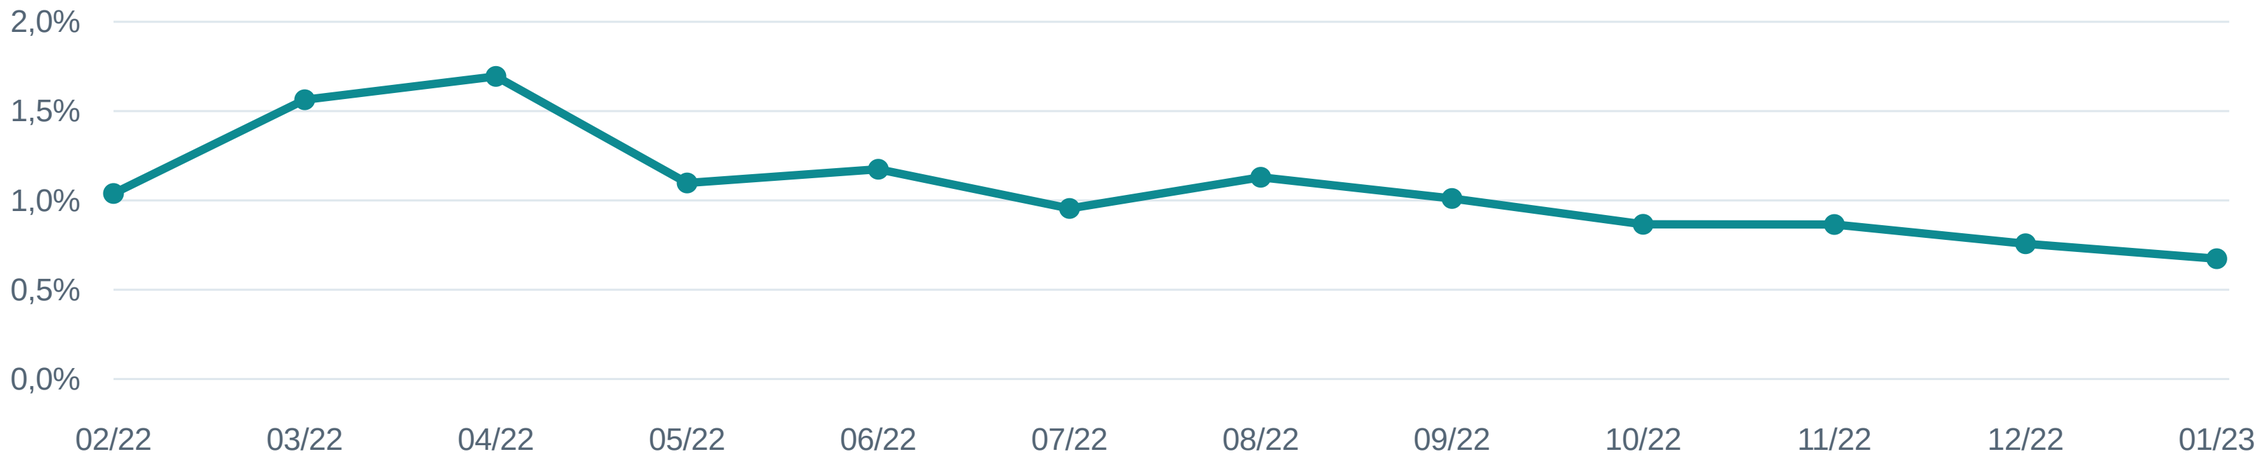
0% Null targets

10,043% NaN diff_trans_date

Time difference between transactions

y_any

Phát sinh sử dụng bất kì sản phẩm nào trong tháng

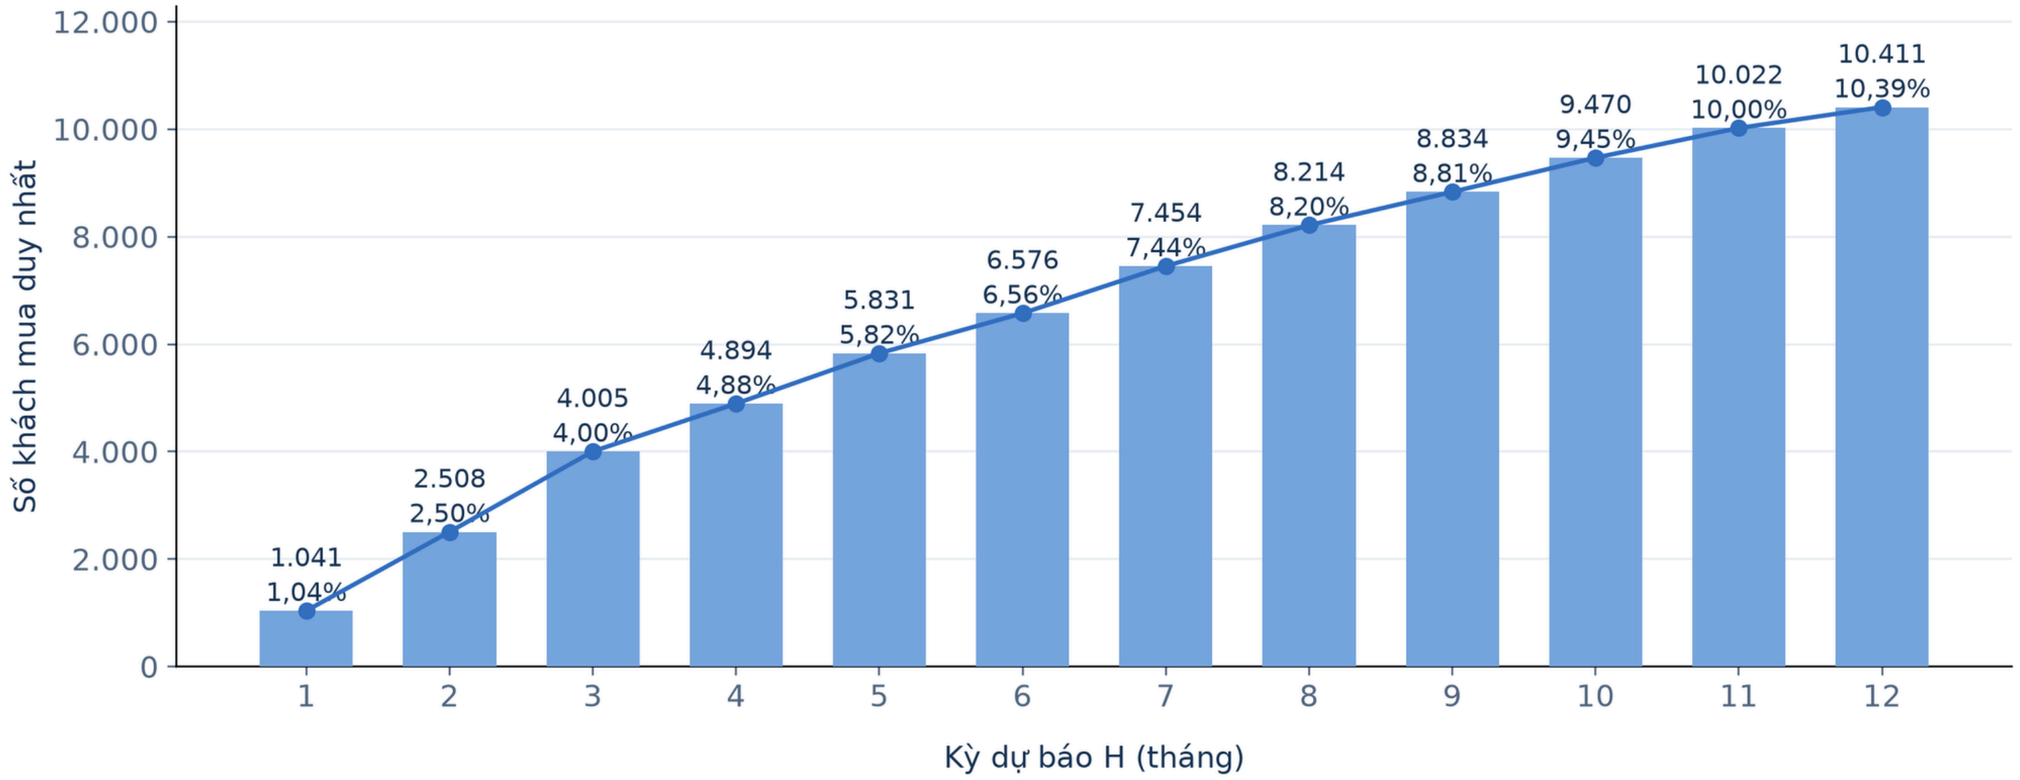


Ưu tiên AP/PR-AUC và Precision, Recall, Lift theo ngân sách

Tỷ lệ mua thay đổi theo tháng. Accuracy đơn thuần không đủ để đánh giá.

Số khách mua khi kéo dài kỳ dự báo H

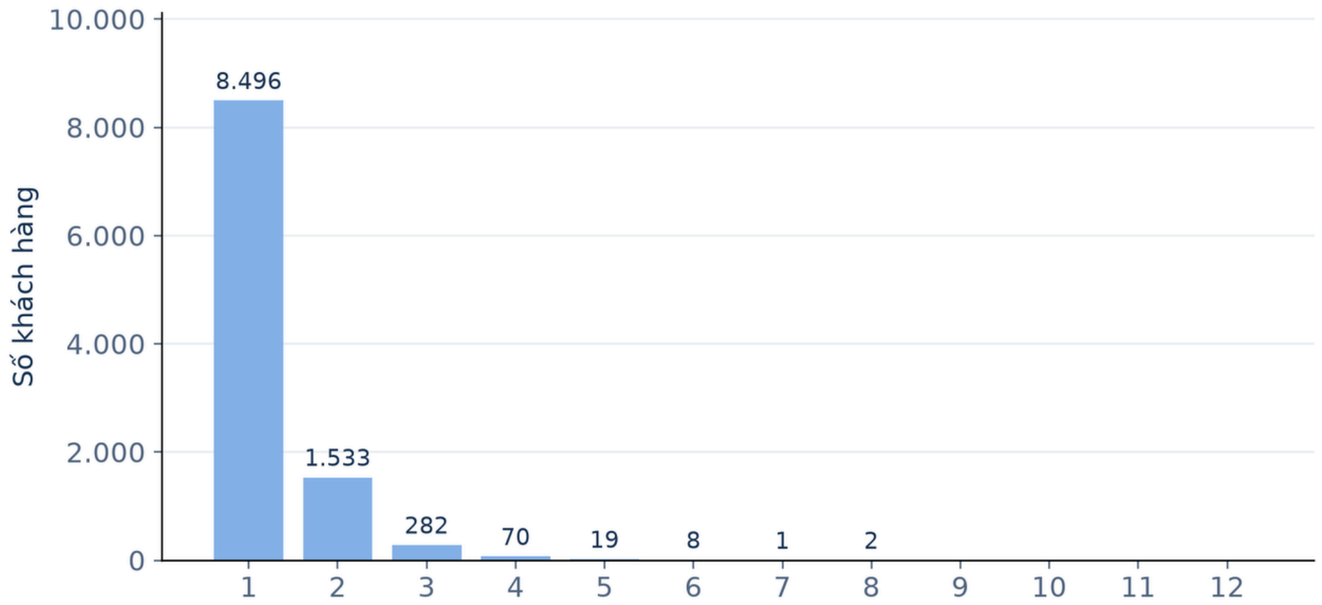
Cùng mốc bắt đầu 01/02/2022 · 100.224 khách · Có ít nhất một target = 1 trong kỳ



một tháng phù hợp với thiết kế nhãn và mục tiêu tiếp cận ngắn hạn, chưa có bằng chứng đó là kỳ hạn tối ưu cho mọi mục tiêu kinh doanh.

Số tháng có mua trên mỗi khách hàng

y_any = 1 · 12 tháng nhãn: 02/2022–01/2023 · 100.224 khách



Khách từng mua

10.411 khách (10.39%)

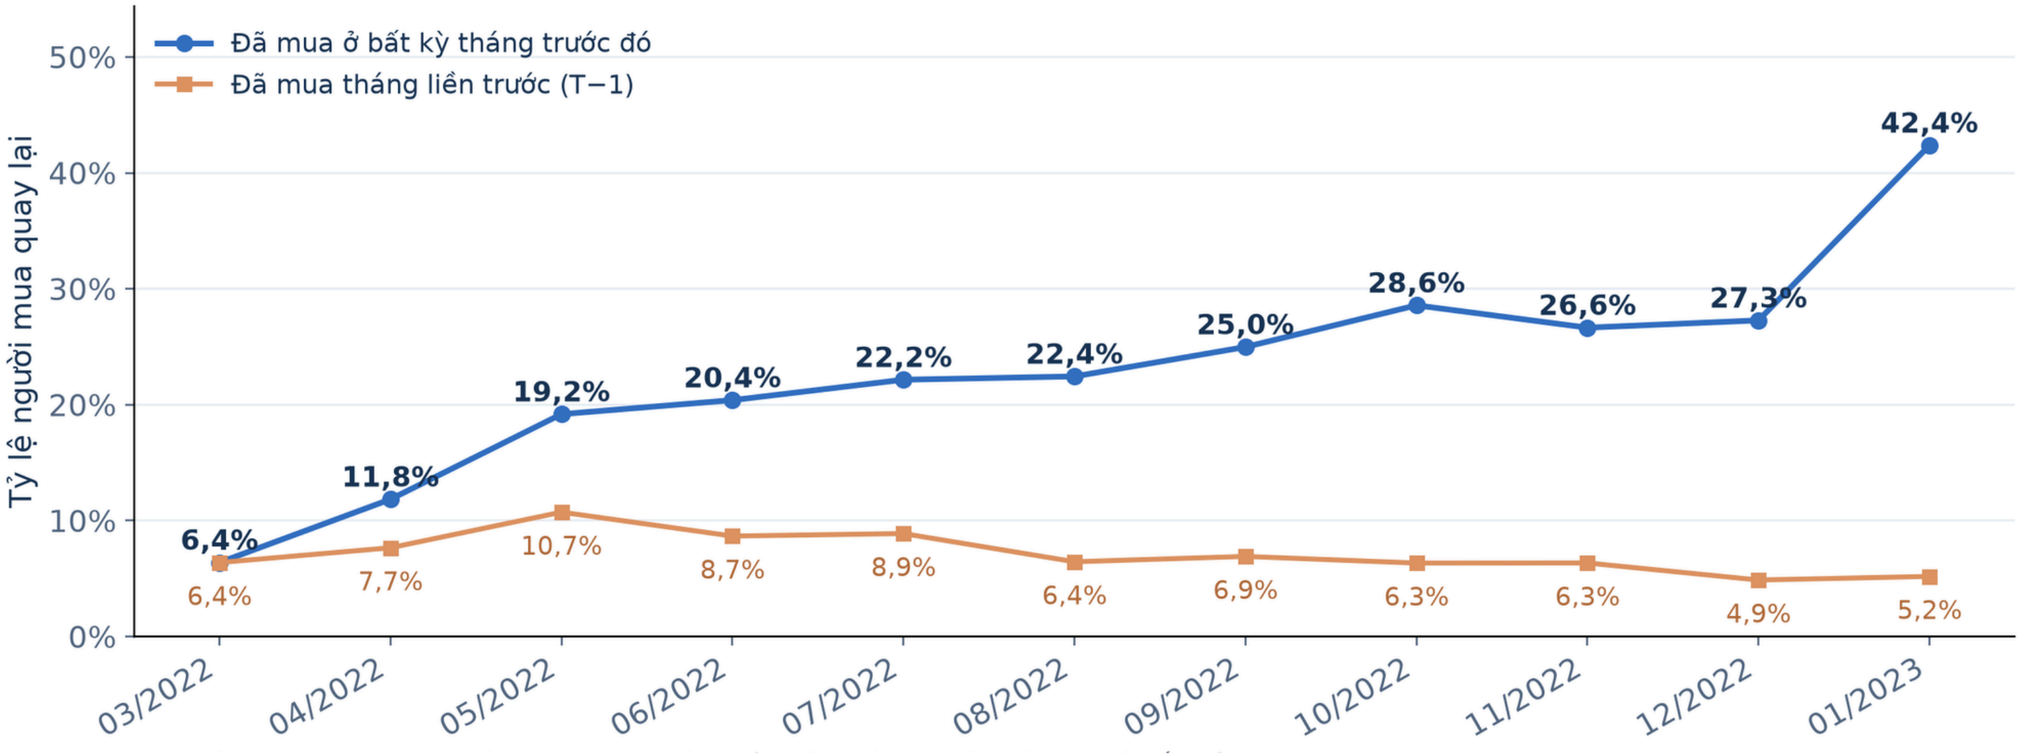
Mean	**1,23**
Median	**1,00**
P75	**1,00**
P90	**2,00**

- **89,61% khách không có tháng nào mua.**
- **Trong nhóm từng mua, 81,60% chỉ mua ở đúng 1 tháng (8.496/10.411 khách).**
- **Chỉ 18,40% người từng mua có mua ở từ 2 tháng trở lên.**

Mô hình cần nhận diện chủ yếu nhóm người chưa mua trong lịch sử dữ liệu

Tỷ lệ mua quay lại theo tháng

Số khách mua quay lại / Tổng số khách có mua trong tháng · y_any



Chỉ dùng nhãn mua tháng trước sẽ bỏ sót lịch sử mua xa hơn.
Nên thử thêm đã từng mua, số tháng từ lần mua gần nhất và số tháng có mua trước cutoff

TRX

ghi nhận giao dịch qua app ngân hàng

Cơ cấu giao dịch theo currency

TRX · Toàn bộ lịch sử · 38.764.930 giao dịch



Mã 11
99,8950% · 38.724.240

12 mã khác
0,1047% · 40.572

Thiếu currency
0,0003% · 118

99.8%

Dữ liệu đầy đủ

amount null 0%
currency là 0,000304% (118 dòng).

0%

Trùng lặp

có 1 trường hợp trùng client_id + event_time

13

Loại tiền tệ

ko kể null

1.5%

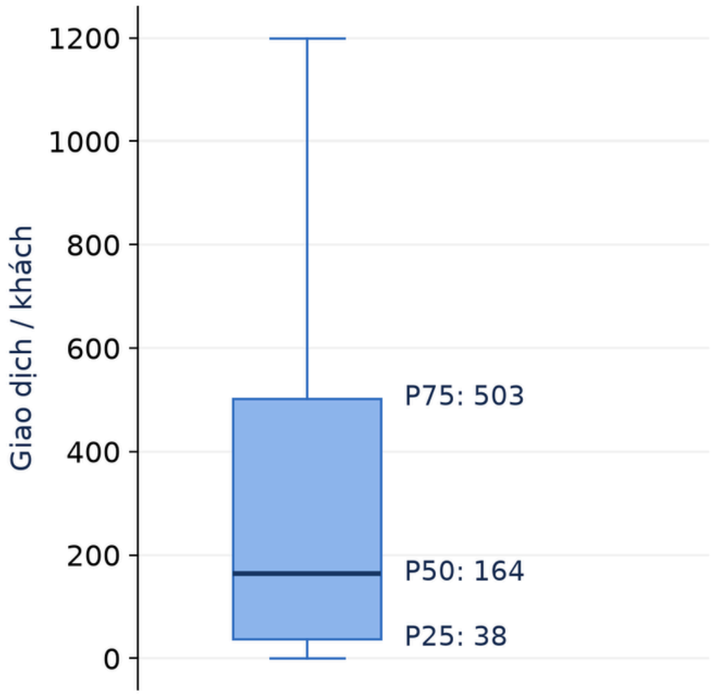
Client_id không có log

1.503 client_id không ghi nhận trx

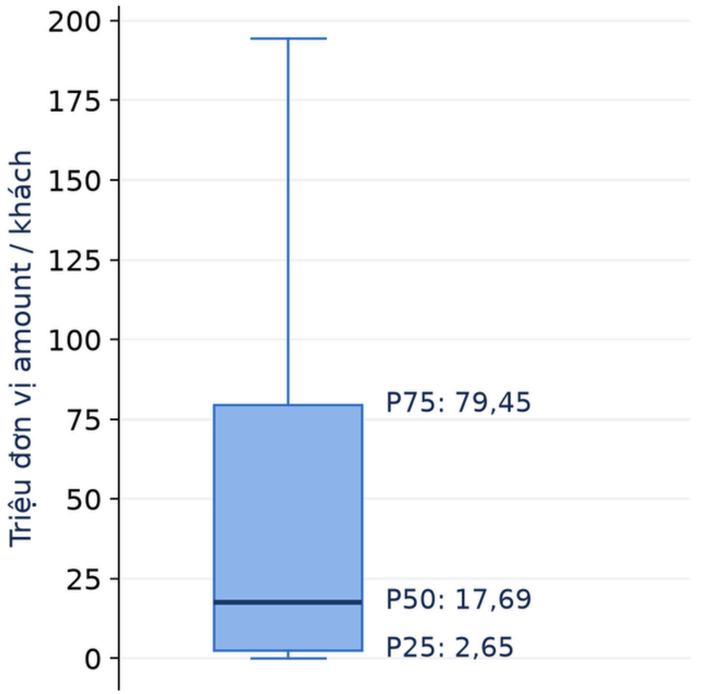
Phân vị giao dịch trên mỗi khách hàng

100.224 khách · Toàn bộ lịch sử · Bao gồm khách không có giao dịch

Số lượng giao dịch



Tổng amount · Currency mã 11



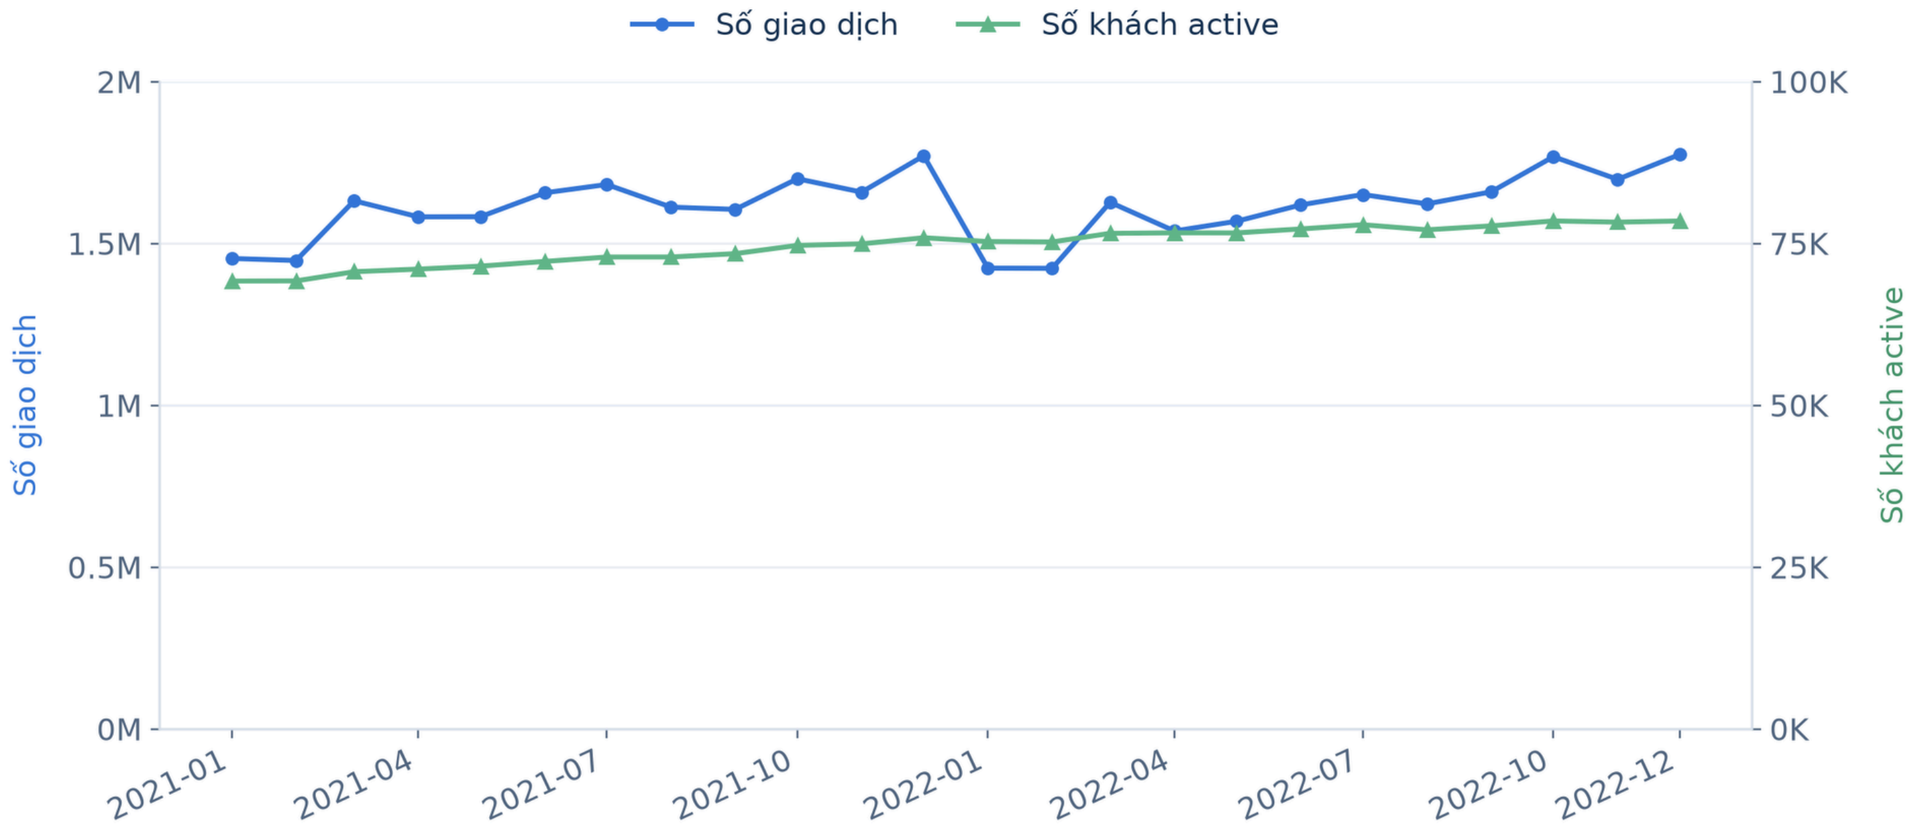
Hộp: P25–P75; đường giữa: trung vị; râu: giới hạn 1,5 × IQR.

Ẩn điểm ngoài râu để dễ đọc; vẫn dùng toàn bộ khách để tính phân vị. Amount chưa quy đổi tiền tệ.

Amount lớn nhất: 1.370.187.366.400 (currency mã 11)
Khách sở hữu có 56 giao dịch, trung vị amount khoảng 164,54 tỷ

Độ phủ & ổn định theo tháng

TRX · Số giao dịch và số khách active · 01/2021–12/2022

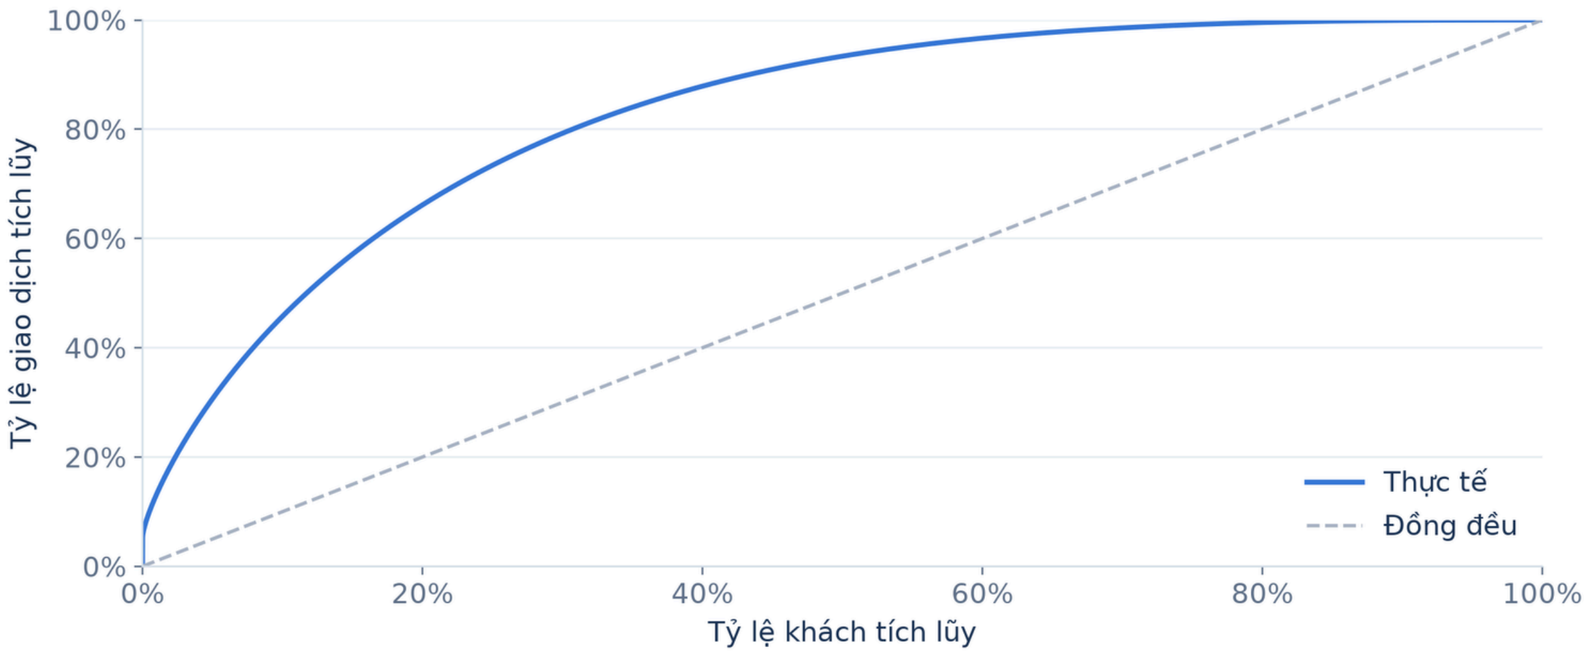


Khách active: có ≥1 giao dịch trong tháng; độ phủ trên 100.224 khách: 69,1%–78,3%.

Độ phủ ổn định theo thời gian, đủ lịch sử xây dựng Customer-month

Mức độ tập trung giao dịch theo khách

TRX · Toàn bộ lịch sử · Xếp khách từ nhiều đến ít giao dịch nhất



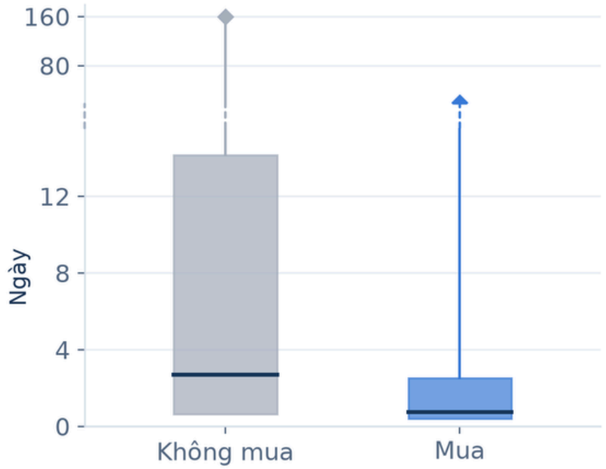
Top 1% khách tạo khoảng 13,16% giao dịch; top 5% tạo khoảng 30,66%.

Hoạt động giao dịch phân hóa rõ giữa các khách hàng, với một nhóm nhỏ khách tích cực đóng góp tỷ trọng giao dịch lớn.

RFM: Mua và Không mua

Nhãn mua ít nhất một sản phẩm trong tháng T · Đơn vị quan sát: khách–tháng

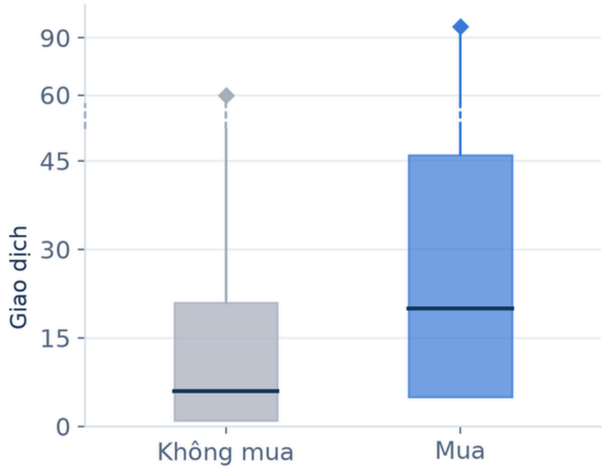
Recency
Số ngày từ giao dịch gần nhất



Mean: 26,43
P95: 160,60

Mean: 6,77
P95: 19,48

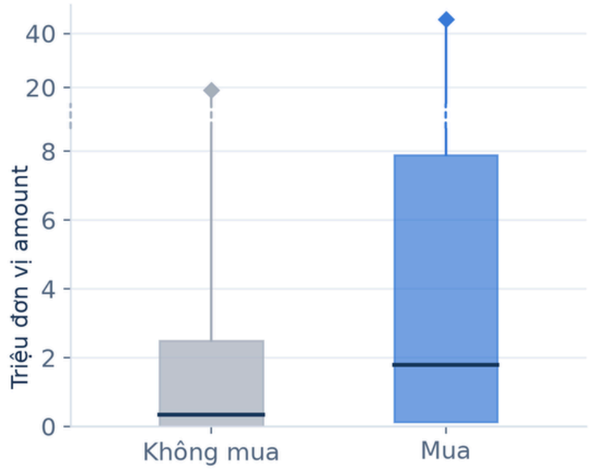
Frequency
Số giao dịch tháng T−1



Mean: 15,95
P95: 60,00

Mean: 31,35
P95: 96,00

Monetary
Tổng amount mã 11 tháng T−1



Mean: 12,16
P95: 19,09

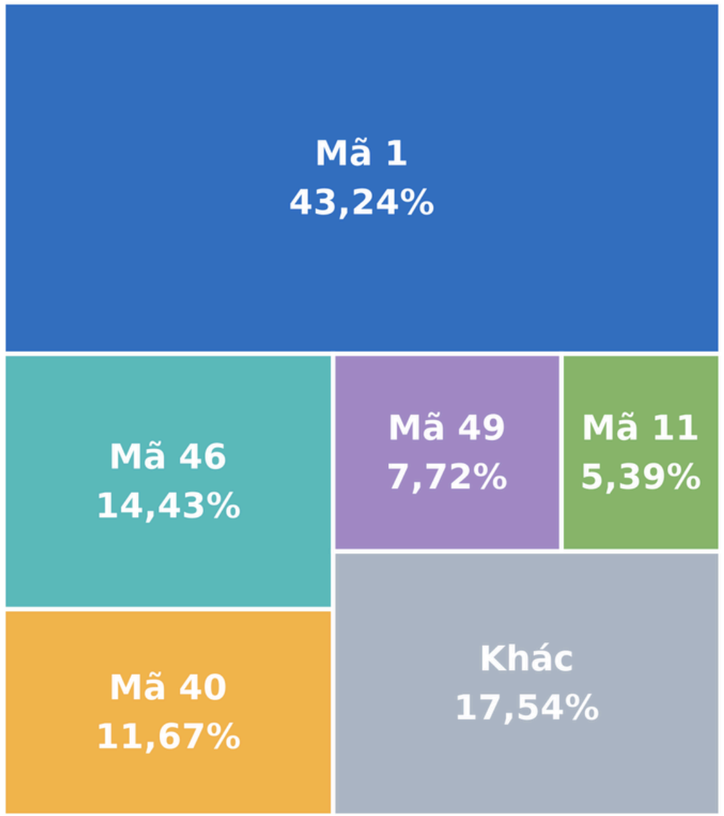
Mean: 33,75
P95: 45,28

Nhóm mua có giao dịch gần hơn, thường xuyên hơn và khối lượng lớn hơn

Top 5 event_type

Tỷ trọng số giao dịch

TRX · Toàn bộ lịch sử

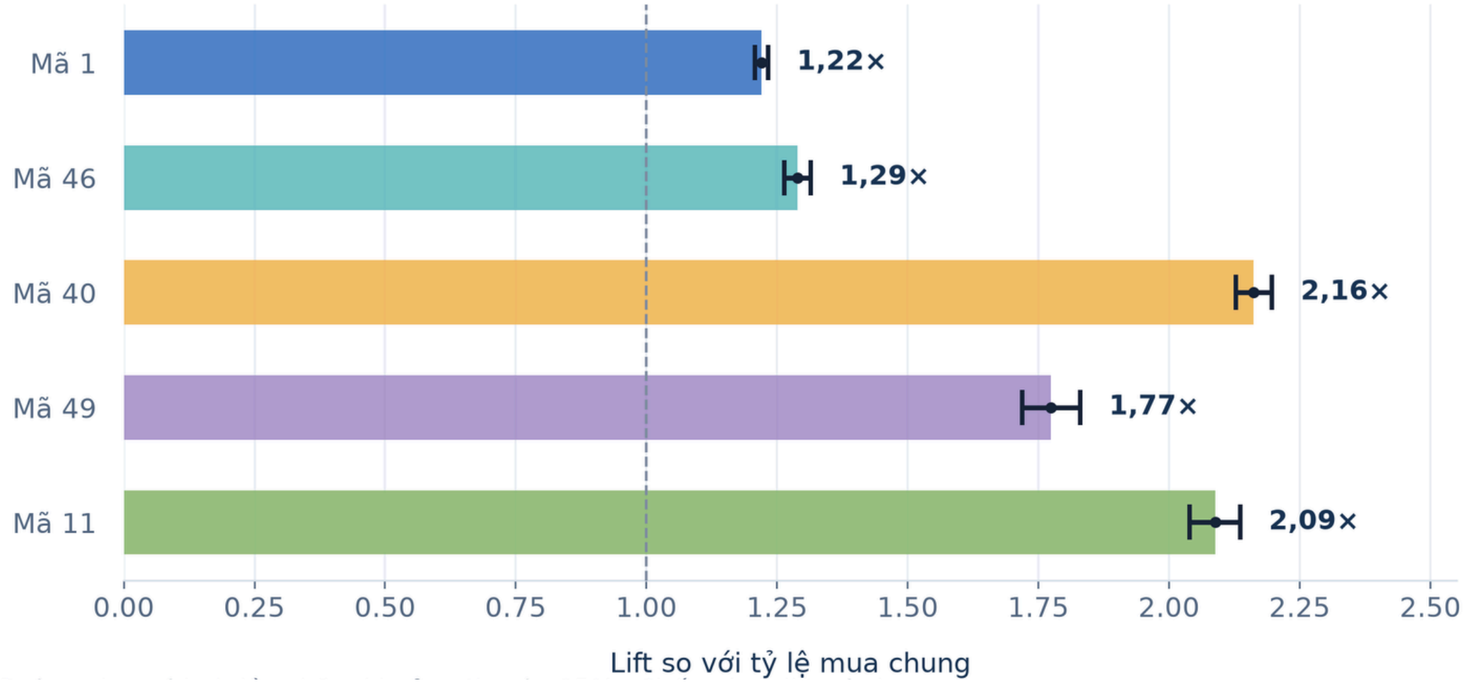


“Khác”: 50 mã còn lại.

Giữ mã gốc; chưa ánh xạ tên nghiệp vụ.

Lift theo event_type

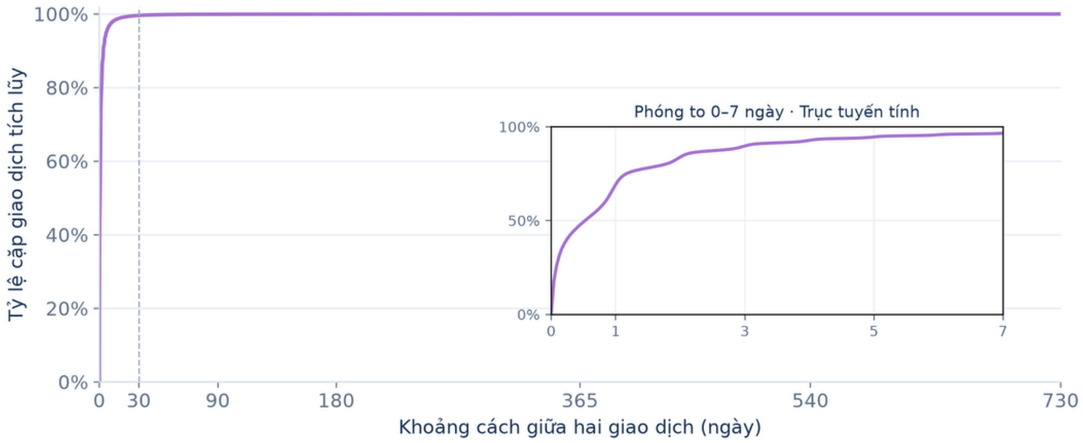
Mua ít nhất một sản phẩm tháng T · Có event_type trong tháng T−1



nên giữ thông tin loại giao dịch khi tạo đặc trưng thay vì chỉ dùng tổng số giao dịch

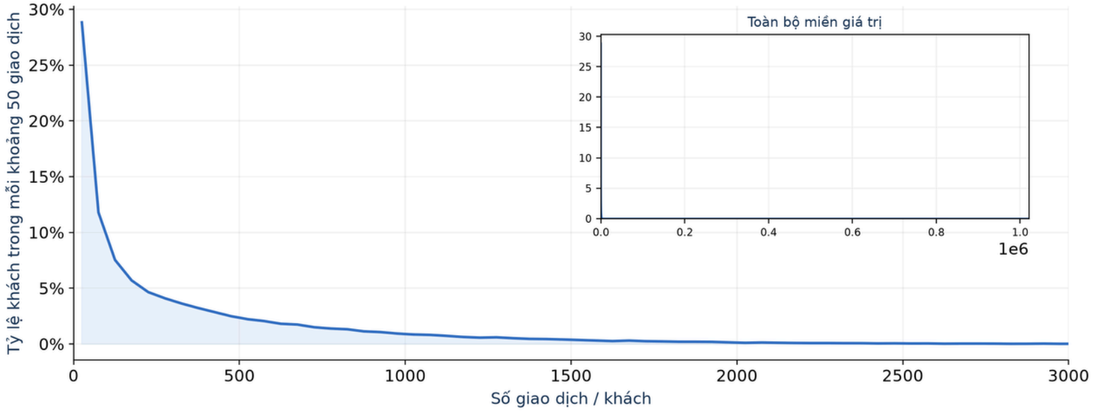
Thời gian giữa hai giao dịch liên tiếp

TRX · Toàn bộ lịch sử · 38.666.209 cặp giao dịch cùng khách



Phân phối số giao dịch mỗi khách

TRX · Toàn bộ lịch sử · 100.224 khách, gồm cả khách không có giao dịch

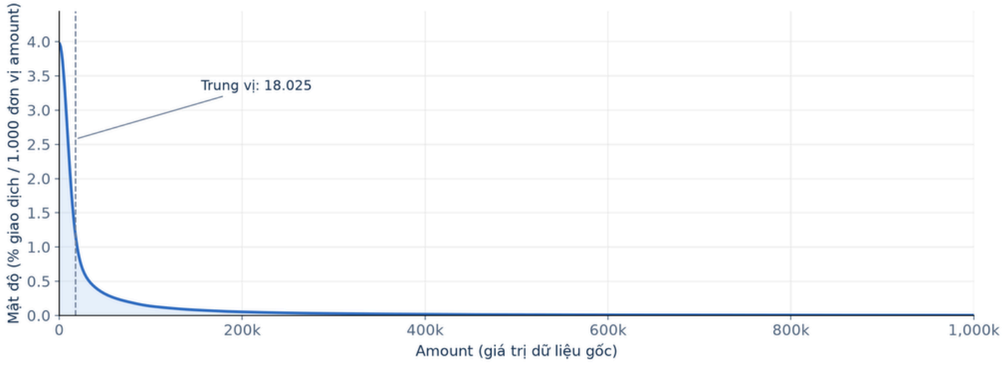


Vùng chính: 0–3.000 giao dịch, chứa 99.69% khách; ô nhỏ giữ toàn bộ đuôi đến 1.020.773.

Đường nối tần suất của các bin đều 50 giao dịch; không làm trơn, không dùng log. Biến số giao dịch là rời rạc.

Phân phối amount · Currency mã 11

Trục amount liên tục · 38.724.240 giao dịch · Không biến đổi log



Phóng vùng 0–1 triệu, chứa 95,43% giao dịch; phần còn lại nằm ngoài khung hiển thị.

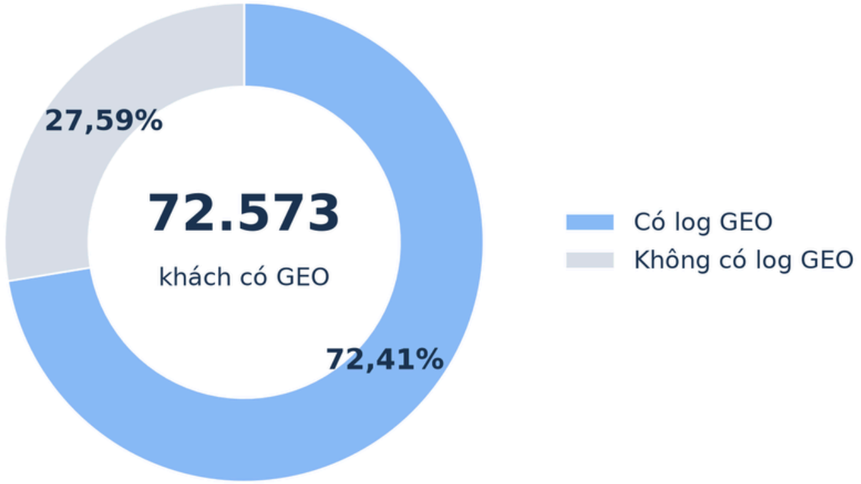
Mật độ ước lượng bằng làm trơn histogram bin đều 1.000 (Gaussian, băng thông 8.000); mẫu số giữ toàn bộ giao dịch.

GEO

Ghi nhận vị trí mở app

0 null

duplicate



CẤP 4

18.948

mã phân biệt

geohash_4

CẤP 5

122.982

mã phân biệt

geohash_5

CẤP 6

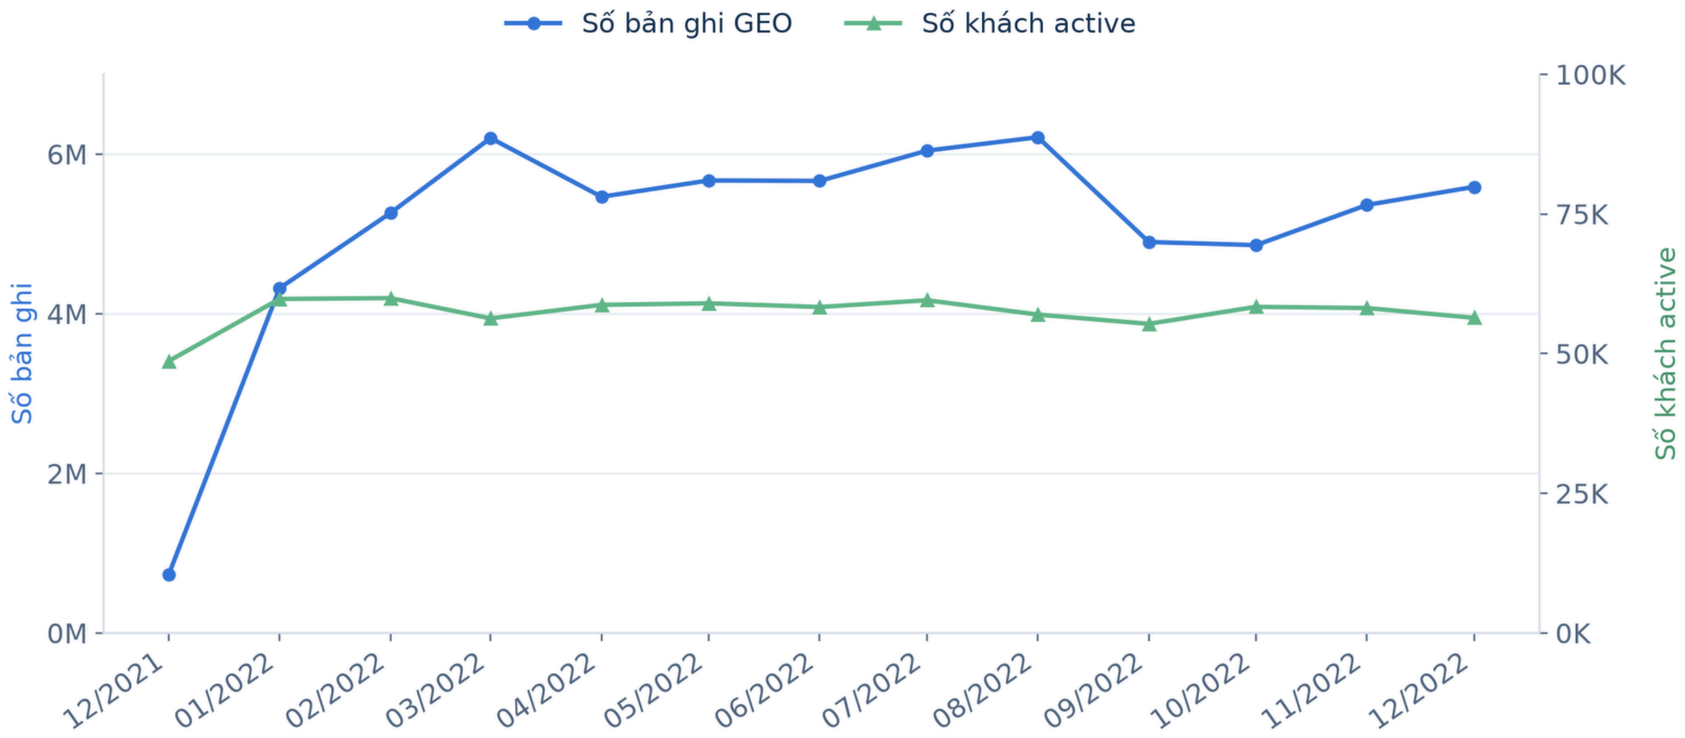
610.866

mã phân biệt

geohash_6

Độ phủ GEO theo tháng

Số bản ghi và số khách active · 12/2021–12/2022



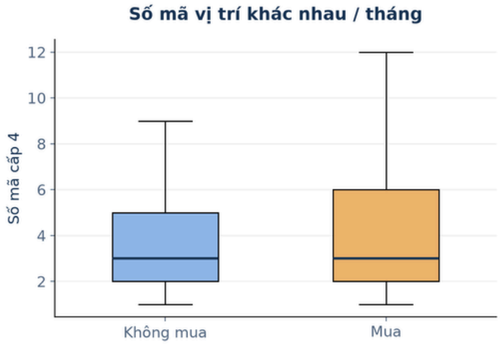
Trên 72.573 khách có log GEO, toàn bộ lịch sử:

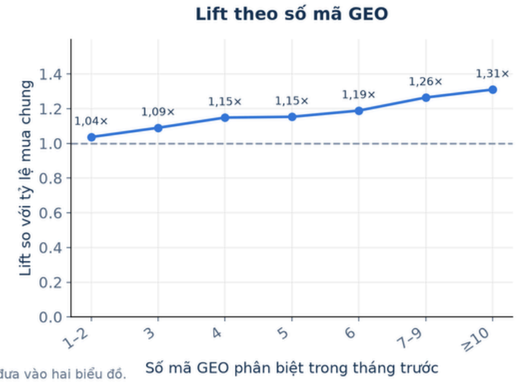
Min: 1 log/khách. **Trung bình: 913,50 log/khách.**

Max: 39.487 log/khách. **Trung vị: 507 log/khách.**

Tín hiệu GEO và khả năng mua

Số mã geohash_4 phân biệt tháng T−1 · Nhãn y_any trong tháng T



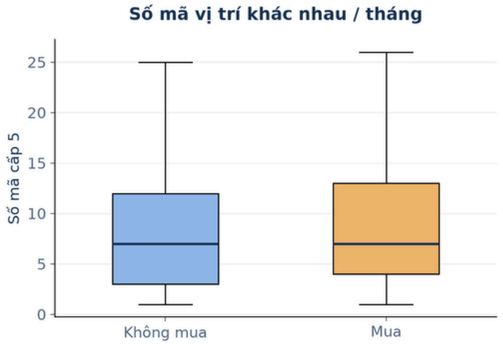


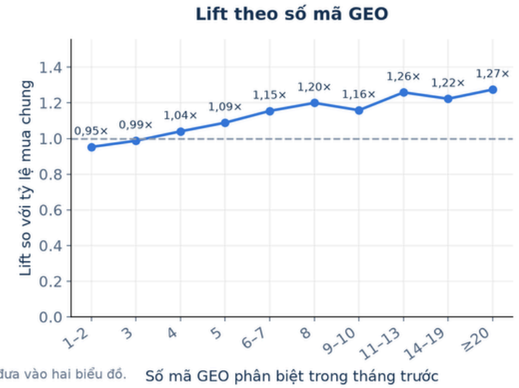
Chỉ quan sát có GEO sử dụng được: 697.171 khách–tháng; nhóm thiếu GEO không đưa vào hai biểu đồ.

Hộp: P25–P75, vạch giữa: trung vị; râu 1,5×IQR, ẩn điểm ngoài râu. Phân vị giữ các giá trị bằng nhau cùng nhóm.

Lift so với tỷ lệ mua chung 1,069%; chưa điều chỉnh lượng log. Liên hệ mô tả, chưa khẳng định khả năng dự báo.

Số mã geohash_5 phân biệt tháng T−1 · Nhãn y_any trong tháng T



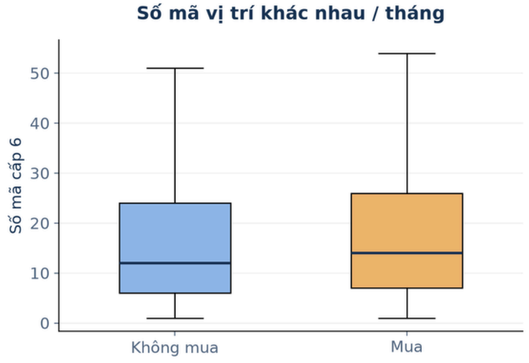


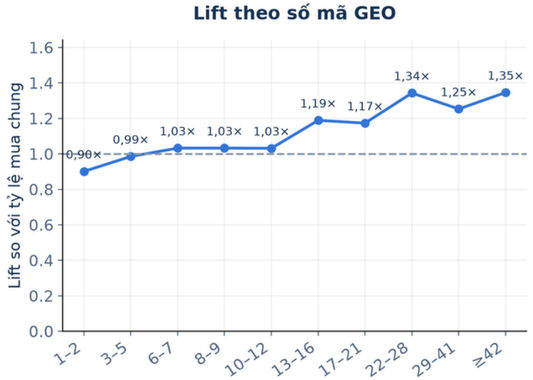
Chỉ quan sát có GEO sử dụng được: 697.171 khách–tháng; nhóm thiếu GEO không đưa vào hai biểu đồ.

Hộp: P25–P75, vạch giữa: trung vị; râu 1,5×IQR, ẩn điểm ngoài râu. Phân vị giữ các giá trị bằng nhau cùng nhóm.

Lift so với tỷ lệ mua chung 1,069%; chưa điều chỉnh lượng log. Liên hệ mô tả, chưa khẳng định khả năng dự báo.

Số mã geohash_6 phân biệt tháng T−1 · Nhãn y_any trong tháng T





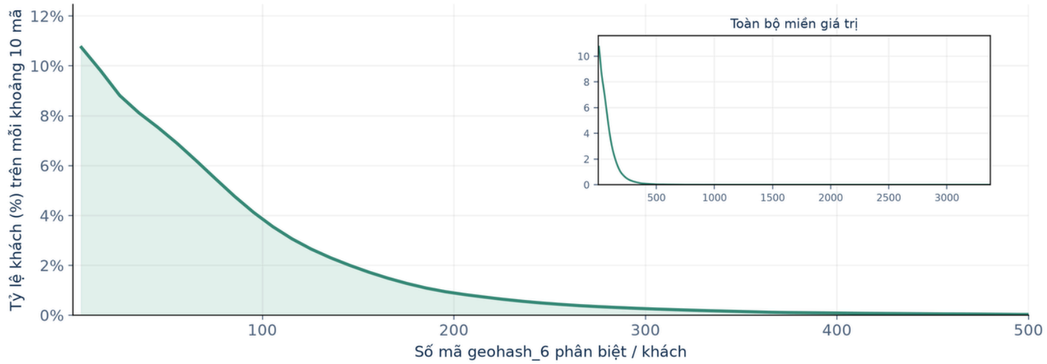
Chỉ quan sát có GEO sử dụng được: 697.171 khách–tháng; nhóm thiếu GEO không đưa vào hai biểu đồ.

Hộp: P25–P75, vạch giữa: trung vị; râu 1,5×IQR, ẩn điểm ngoài râu. Phân vị giữ các giá trị bằng nhau cùng nhóm.

Lift so với tỷ lệ mua chung 1,069%; chưa điều chỉnh lượng log. Liên hệ mô tả, chưa khẳng định khả năng dự báo.

Số mã GEO cấp 6 khác nhau trên mỗi khách

Chỉ khách có GEO: 72.573 · Trung bình: 79,79 · Trung vị: 57,00 · P95: 234,00



Đã loại 27.651 khách không có GEO. Vùng chính 1–500 mã chứa 99,61% khách có GEO.

Đường làm trơn từ bin đều 10 mã (Gaussian, σ=12 mã); hai trục tuyến tính, không dùng log.

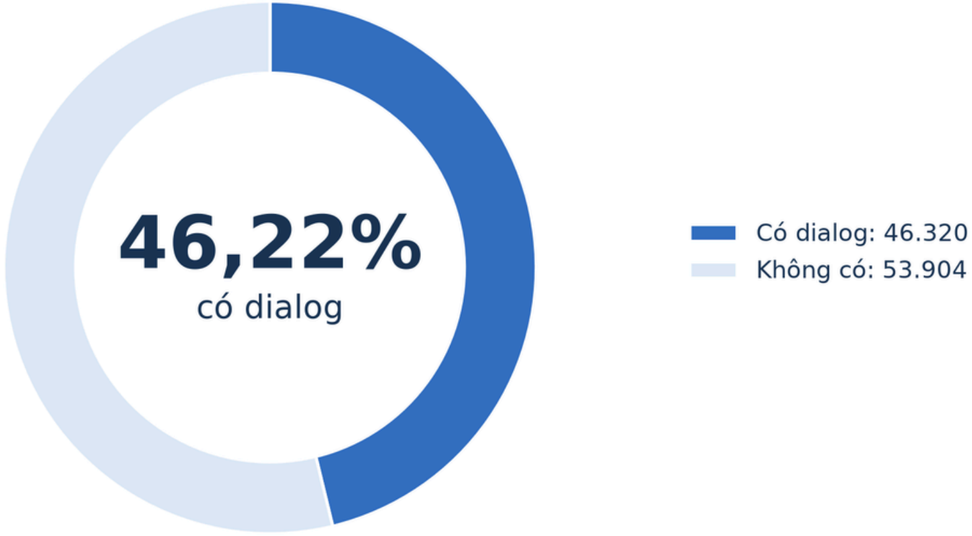
Biến số mã là rời rạc; đường cong chỉ biểu diễn phân phối làm trơn. Ô nhỏ giữ phần đuôi đến 3.374 mã.

DIALOG

Ghi nhận hội thoại

1 cột embedding 768 chiều

0 Null
Vector bằng 0
vector sai số chiều



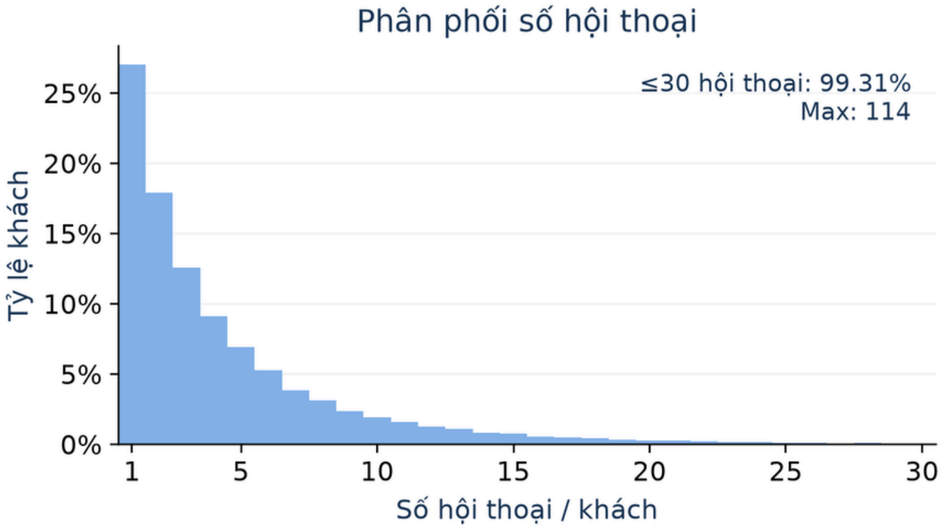
- Technical support.
- Sales calls.
- Service calls
- Negotiations with managers.

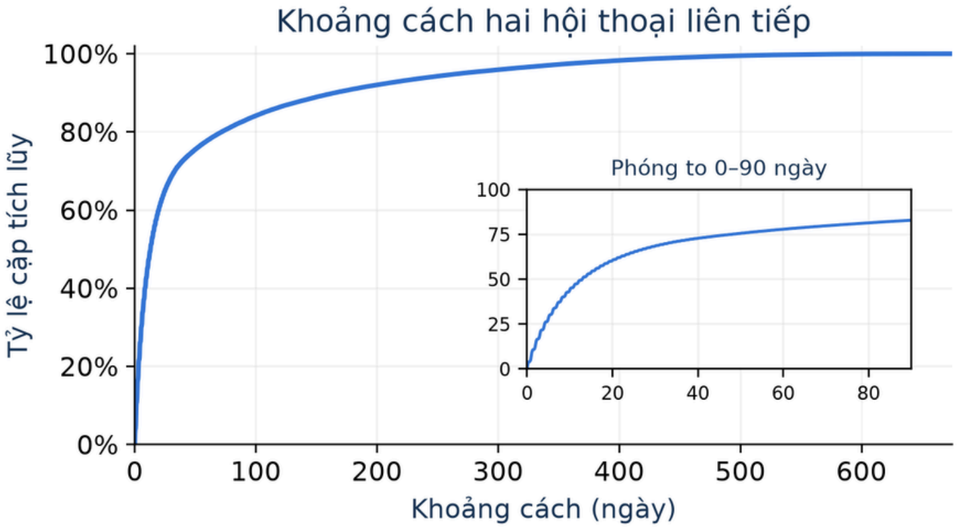


Trong 10 411 khách từng phát sinh mua t

Đặc điểm tương tác hội thoại

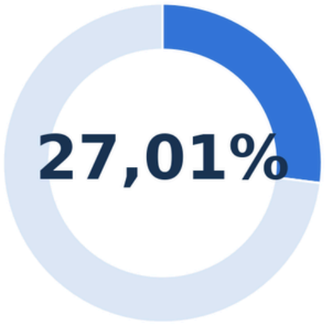
Toàn bộ lịch sử · Chỉ 46.320 khách có dialog · Không dùng log hoặc biến đổi log





Trung vị số hội thoại	**3**
P95 số hội thoại	**15**
Trung vị số ngày active	**3**
Tỷ trọng log từ top 10% khách	**37.15%**
Trung vị khoảng cách hội thoại	**12.93 ngày**

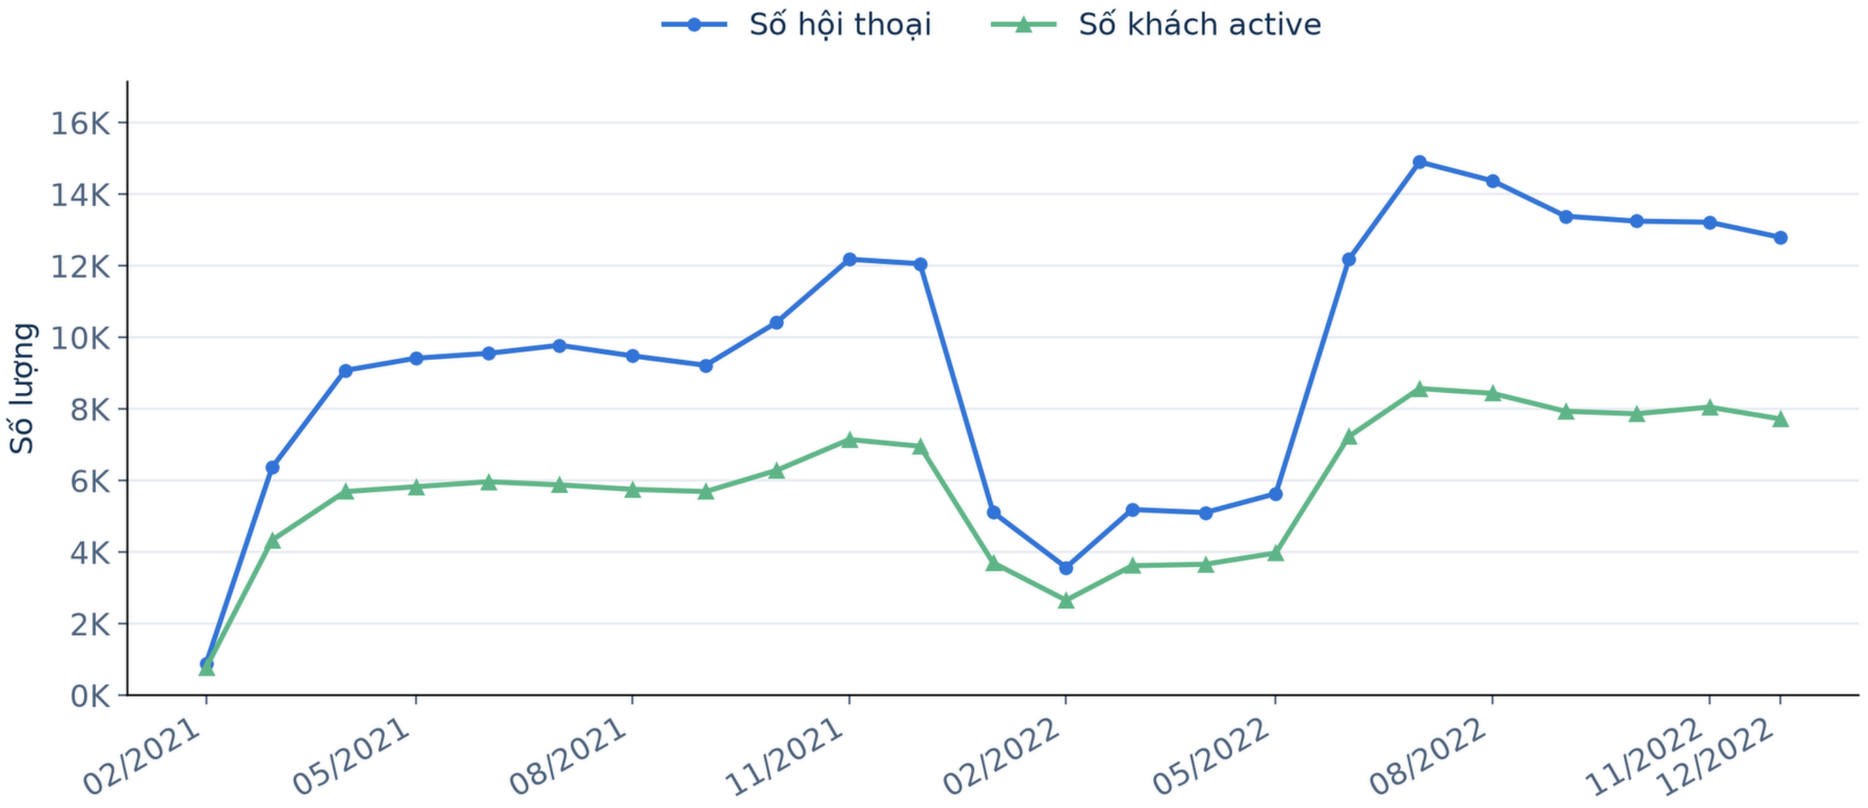
Khách chỉ có 1 hội thoại



12.513 / 46.320 khách

Số hội thoại và khách active theo tháng

DIALOG · Toàn bộ lịch sử 02/2021–12/2022



Có nguồn hành vi và tỷ lệ mua tháng sau

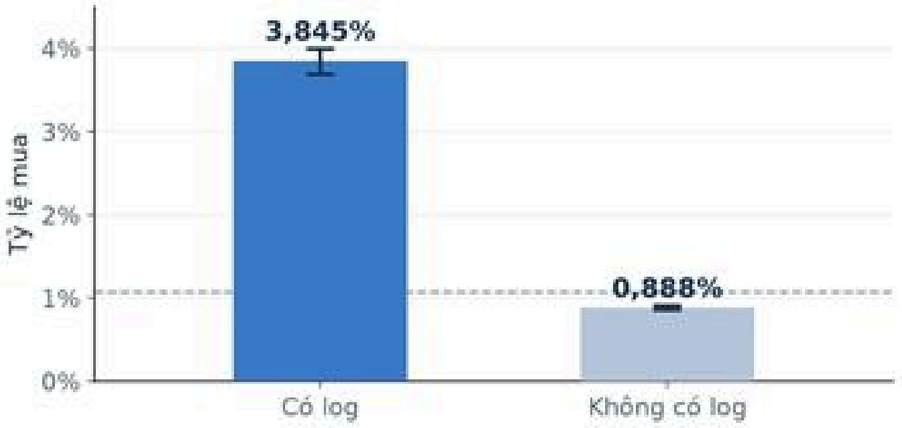
Có/không có log tháng T−1 → y_any tháng T · Gộp 12 tháng nhãn · Đơn vị: khách-tháng

GEO



	Có log	Không có log
n khách-tháng	697.171	505.517
Lượt có mua	8.375	4.479
Tỷ trọng lượt mua	65,15%	34,85%
Lift	1,12×	0,83×

DIALOG



	Có log	Không có log
n khách-tháng	73.455	1.129.233
Lượt có mua	2.824	10.030
Tỷ trọng lượt mua	21,97%	78,03%
Lift	3,60×	0,83×

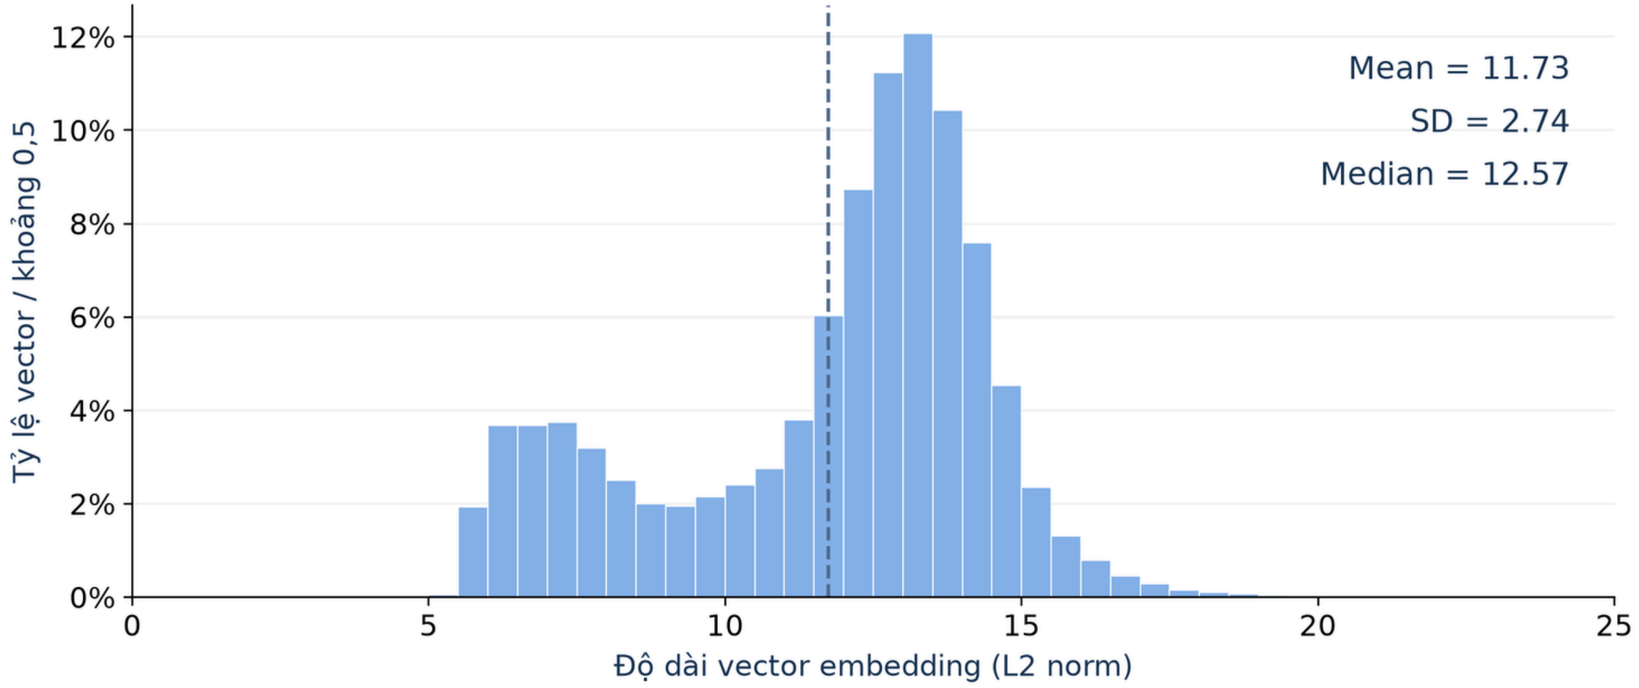
CI 95%: bootstrap theo client_id, 2.000 lần (seed 42). Lift = tỷ lệ mua nhóm / tỷ lệ mua chung (1,069%).

Tỷ trọng lượt mua = số khách-tháng có mua của nhóm / tổng 12.854 khách-tháng có mua.

Hai nhóm có/không trong mỗi nguồn bổ sung nhau; GEO và DIALOG có thể chồng lấn. Không suy ra quan hệ nhân quả.

Phân phối độ dài embedding hội thoại

217.205 vector · 768 chiều · Chuẩn L2 · Toàn bộ dữ liệu

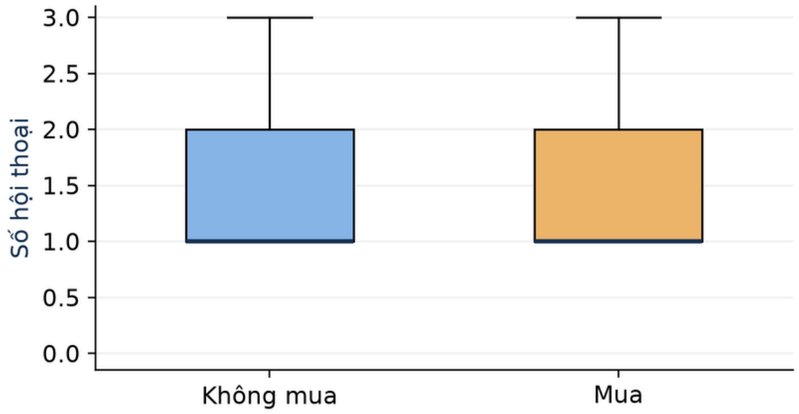


L2 là cách đo độ dài của một vector: $||v||_2 = \sqrt{(v_1^2 + v_2^2 + \ldots + v_{768}^2)}$

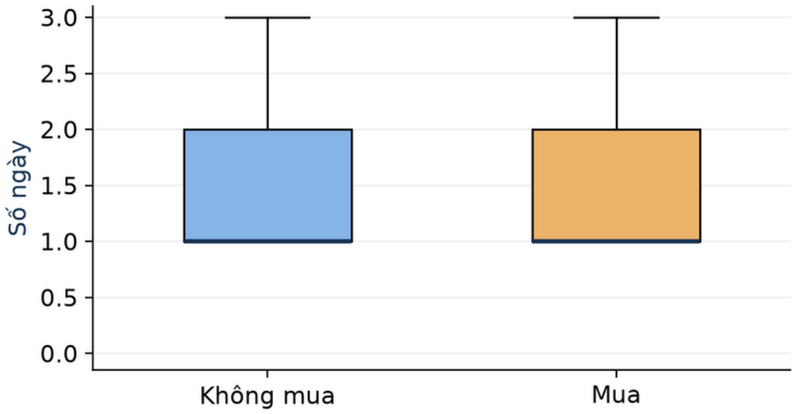
Metadata trên nhóm có hội thoại

Chỉ khách–tháng có ≥1 dialog trong tháng T−1 · Nhãn y_any tháng T

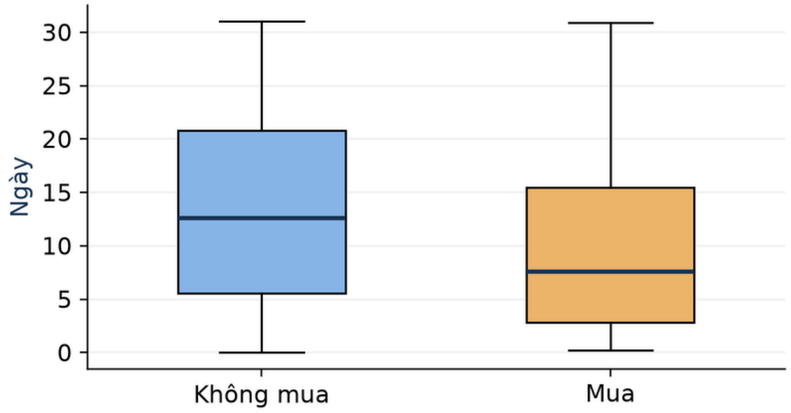
Số hội thoại / khách · Tháng T−1



Số ngày có hội thoại · Tháng T−1



Recency · Trước đầu tháng T



Tập trung vào ngày nhiều hội thoại nhất

